



# Data Science Framework

## (第 4 章 數據科學分析架構)

Chia-Yen Lee, Ph.D. (李家岩 博士)

Department of Information Management (資訊管理學系)  
National Taiwan University (國立台灣大學)

- 第一章 製造數據科學
- 第二章 製造系統分析與管理
- 第三章 數據科學基礎與模型評估
- **第四章 數據科學分析架構與系統運算決策**
- 第五章 數據預處理與製造數據特性
- 第六章 線性分類器
- 第七章 無母數迴歸與分類
- 第八章 決策樹與集成學習
- 第九章 特徵挑選與維度縮減
- 第十章 類神經網路與深度學習
- 第十一章 集群分析
- 第十二章 特徵工程、數據增強與數據平衡
- 第十三章 故障預測與健康管理
- 第十四章 可解釋人工智慧
- 第十五章 概念漂移
- 第十六章 元啟發式演算法
- 第十七章 強化學習

藍：老師課堂講授

綠：學生自學

- 附錄A 線性迴歸
- 附錄B 支持向量機
- 附錄C 統計製程管制與先進製程控制
- 附錄D 超參數最佳化

## ● 應用涵蓋

產能規劃、瑕疵檢測、製程監控與診斷、機台保養、需求預測、生產排程、電腦視覺、自動光學檢測、原料價格預測與採購等

## □ 數據科學分析架構(Data Science Analytics Framework, DSAF)

### ● 問題定義

- 問題定義主要用於找到對的問題，定義其瓶頸與目標，進行提案設計與評估

### ● 數據分析

- 數據分析透過數學統計與機器學習技術，對提案進行進一步的建模，找出重要因子、建構因果關係與分類器(classifier)

### ● 決策支援

- 決策支援是將模型產生的結果連結到現場執行面(上線、落地)的決策與資源，考慮到決策風險權衡，以及模型的適應性與擴充性

# 數據科學分析架構




問題定義

1. 有價值/品質的
2. 異質多元的
3. 場域知識相關

數據分析

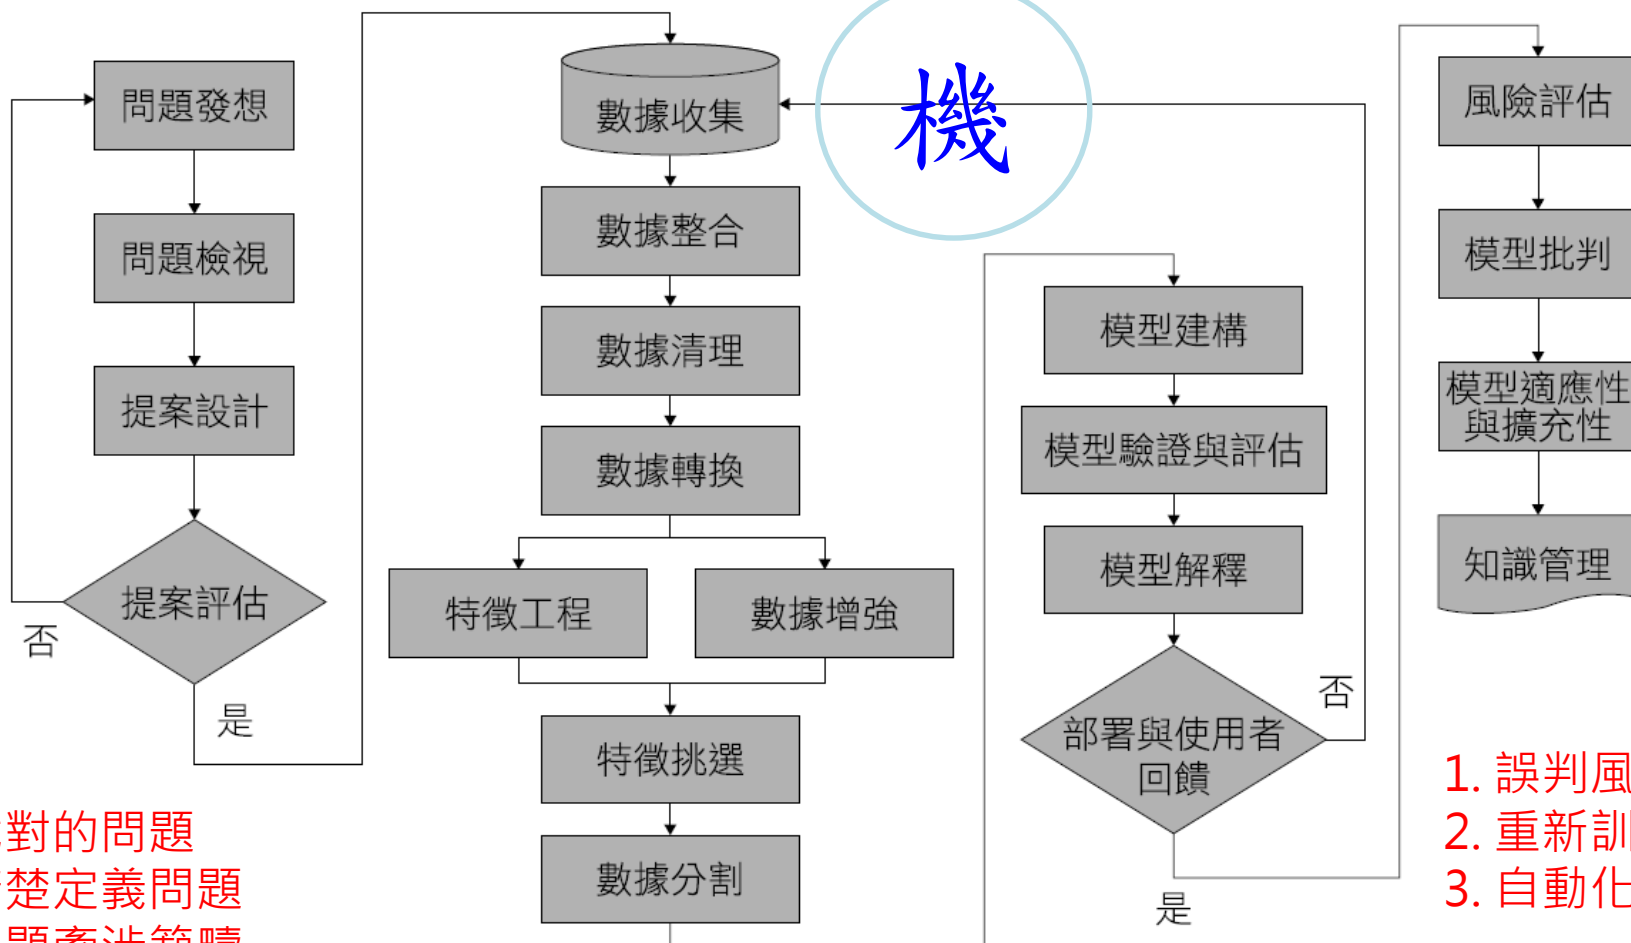
1. 假設與背景
2. 使用時機
3. 優與劣

決策支援



數據準備  
(Data-Focused)

模型建構  
(Model-Focused)



1. 找對的問題
2. 清楚定義問題
3. 問題牽涉範疇

1. 誤判風險權衡
2. 重新訓練適性調整
3. 自動化與知識管理

## □ 「人工智慧」關注於數據分析

- 主要為數據與模型導向(data and model-oriented)。
- 固定且生硬的規則無法滿足現場動態的調整
- 期望透過不斷更新的數據中學習，能跟上環境的變化以提供更好的預測準確度與決策彈性。

## □ 「工人智慧」關注於問題定義與決策支援

- 主要為決策與資源導向(decision and resource-oriented)。
- 現場改善的執行一定牽涉跨組織跨流程的資源協調(resource coordination)，也就是現場常開會溝通、打電話、寫email等的軟性技能與工作，目前也是工人智慧展現的焦點。

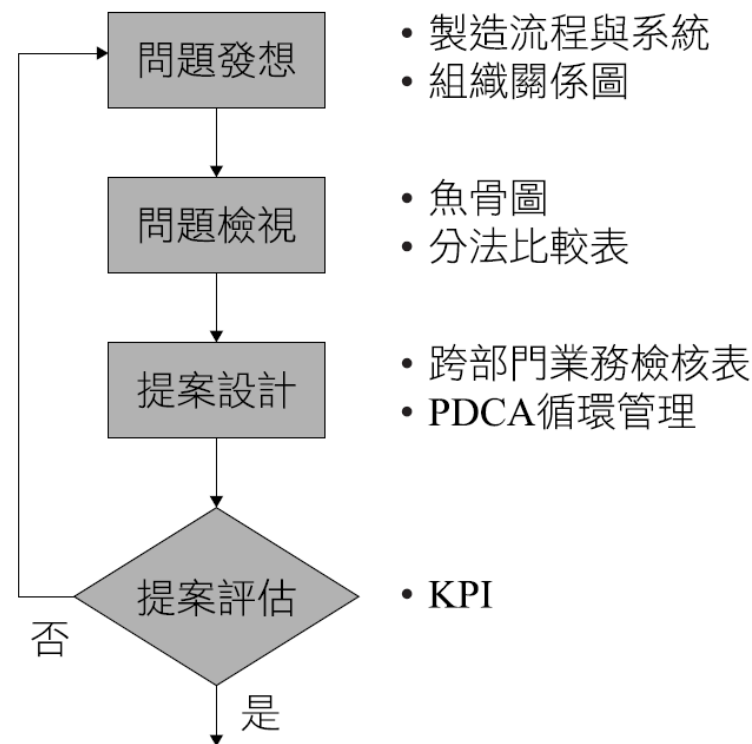
# 問題定義

## □ 問題發想

- 一個精確的問題不僅是能解決一個「點」上的問題，而是要能牽引到「面」上。

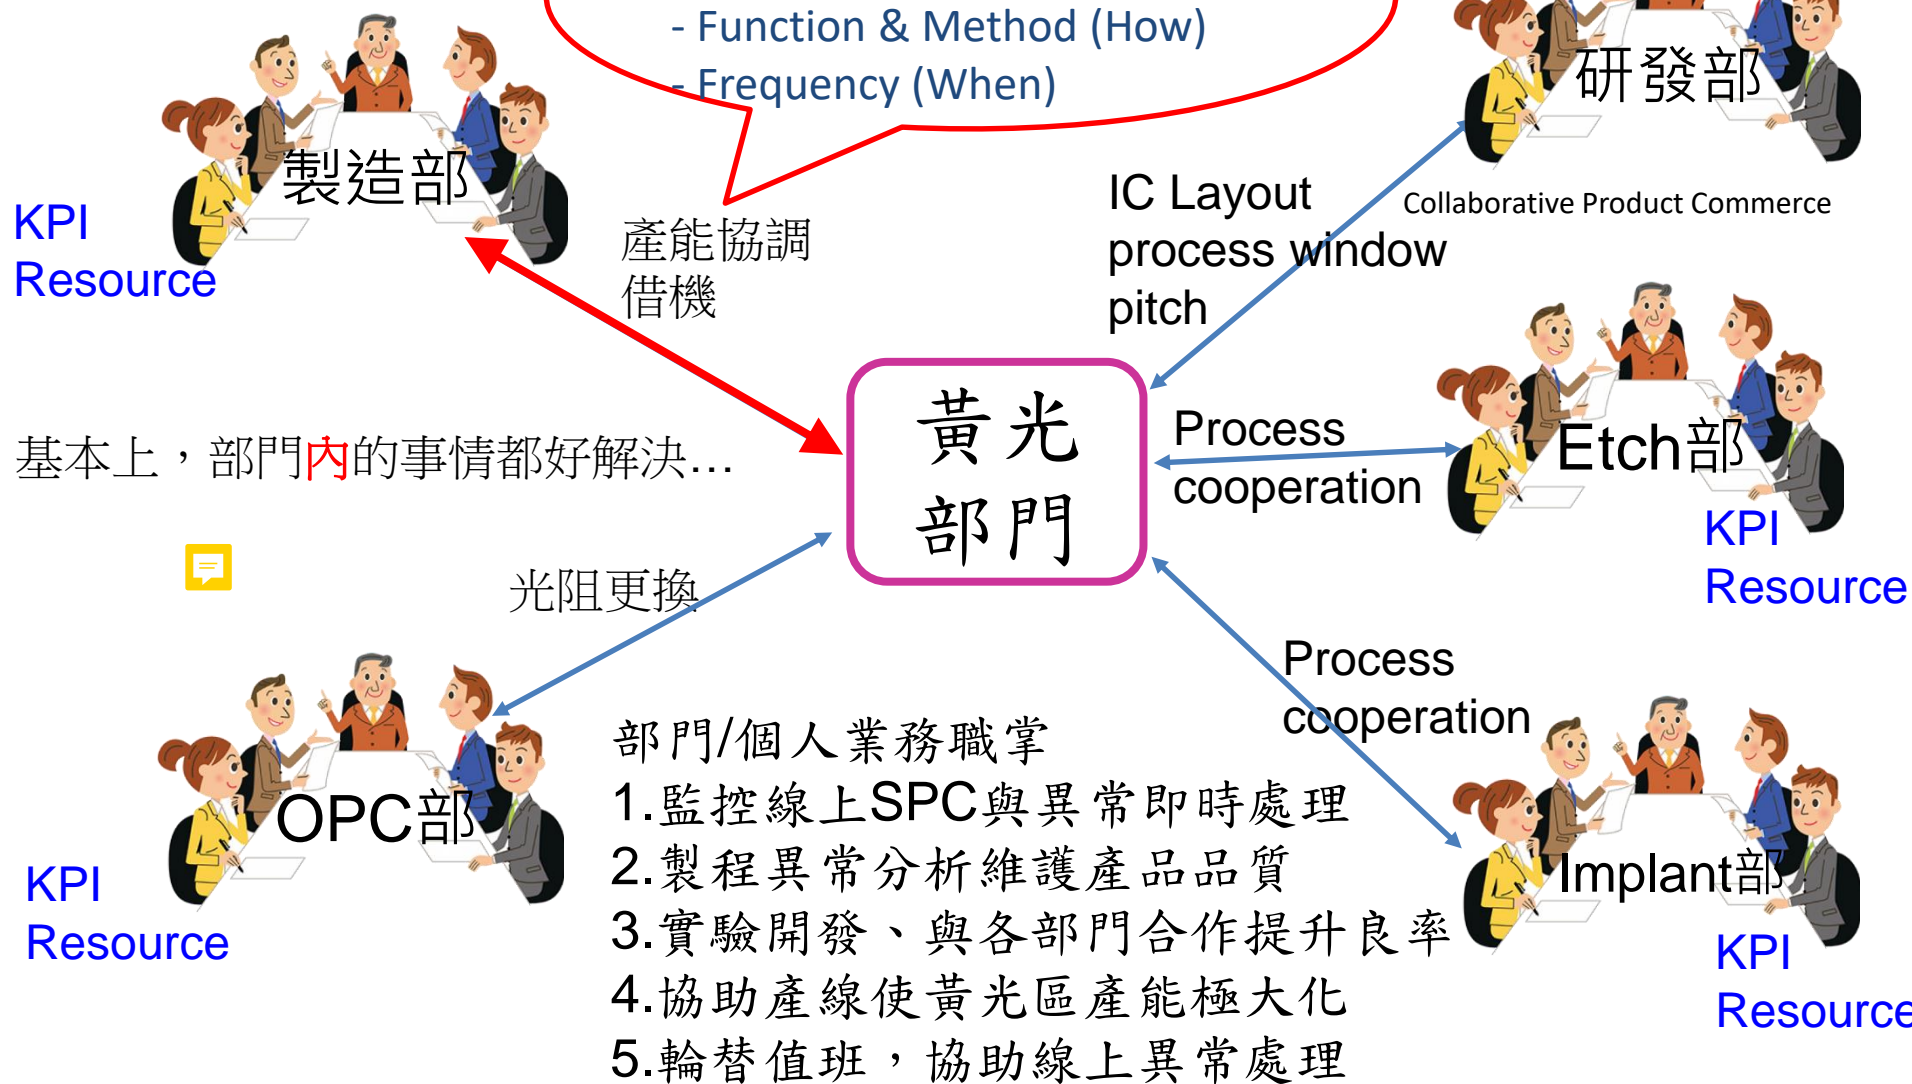
**勘誤更正(p.126)**

- 綜效 (synergy)
  - 「一加一大於二」或「雙贏」。
- 從「企業 / 製造流程」(manufacturing process) 與「組織關聯」(organization association) 開始進行思考。
- 「管理」就是「管資源、理流程」，找出「瓶頸站」，以及從組織關係中點出常需要「資訊溝通」與「資源協調」之所在。



# 問題定義

## 組織/部門關聯圖





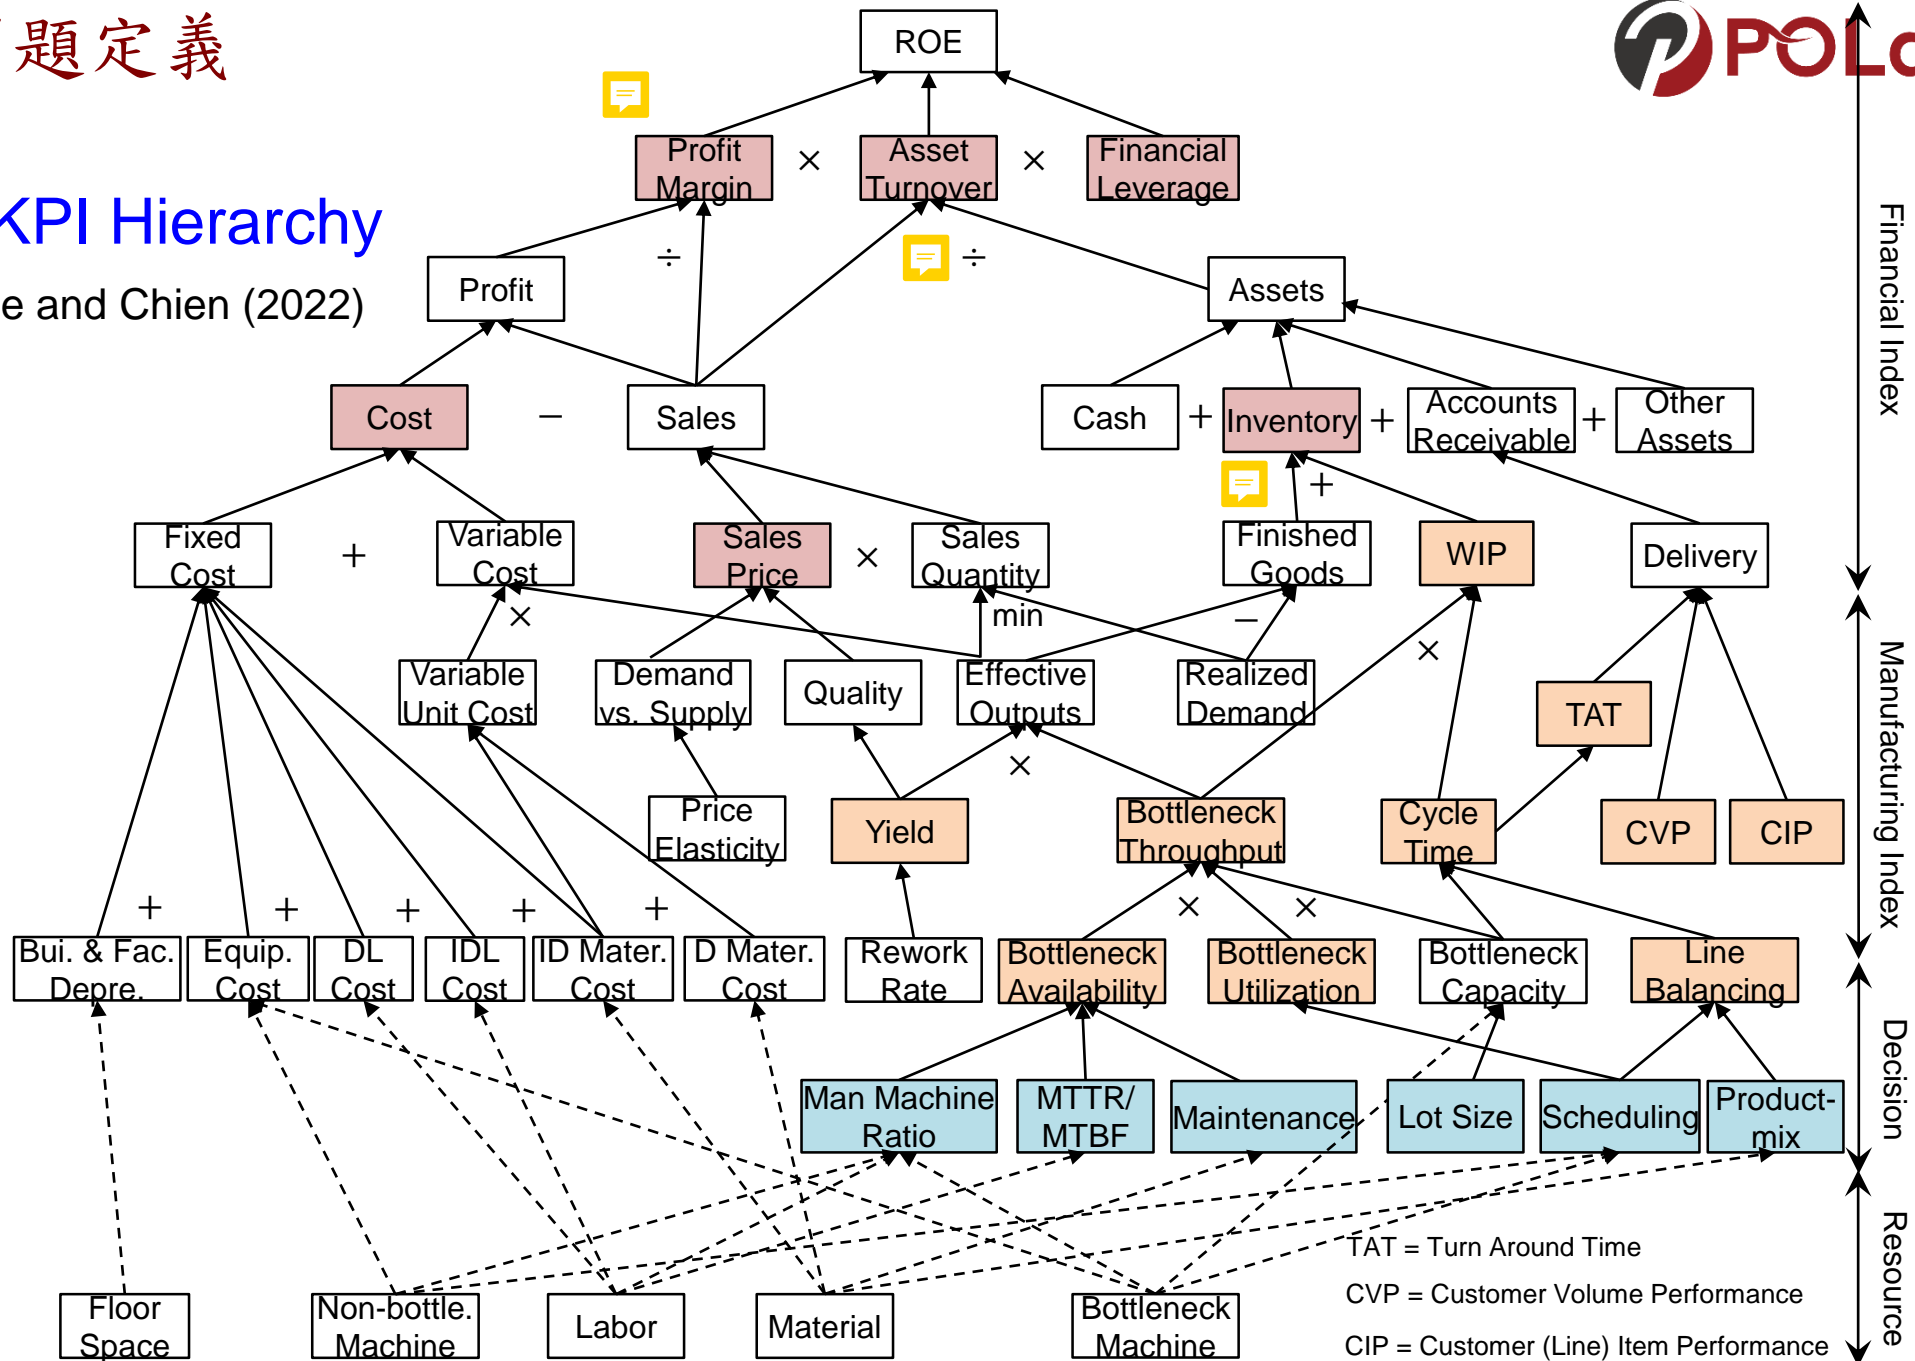
# Enterprise Resource Planning (ERP)





KPI Hierarchy

Lee and Chien (2022)



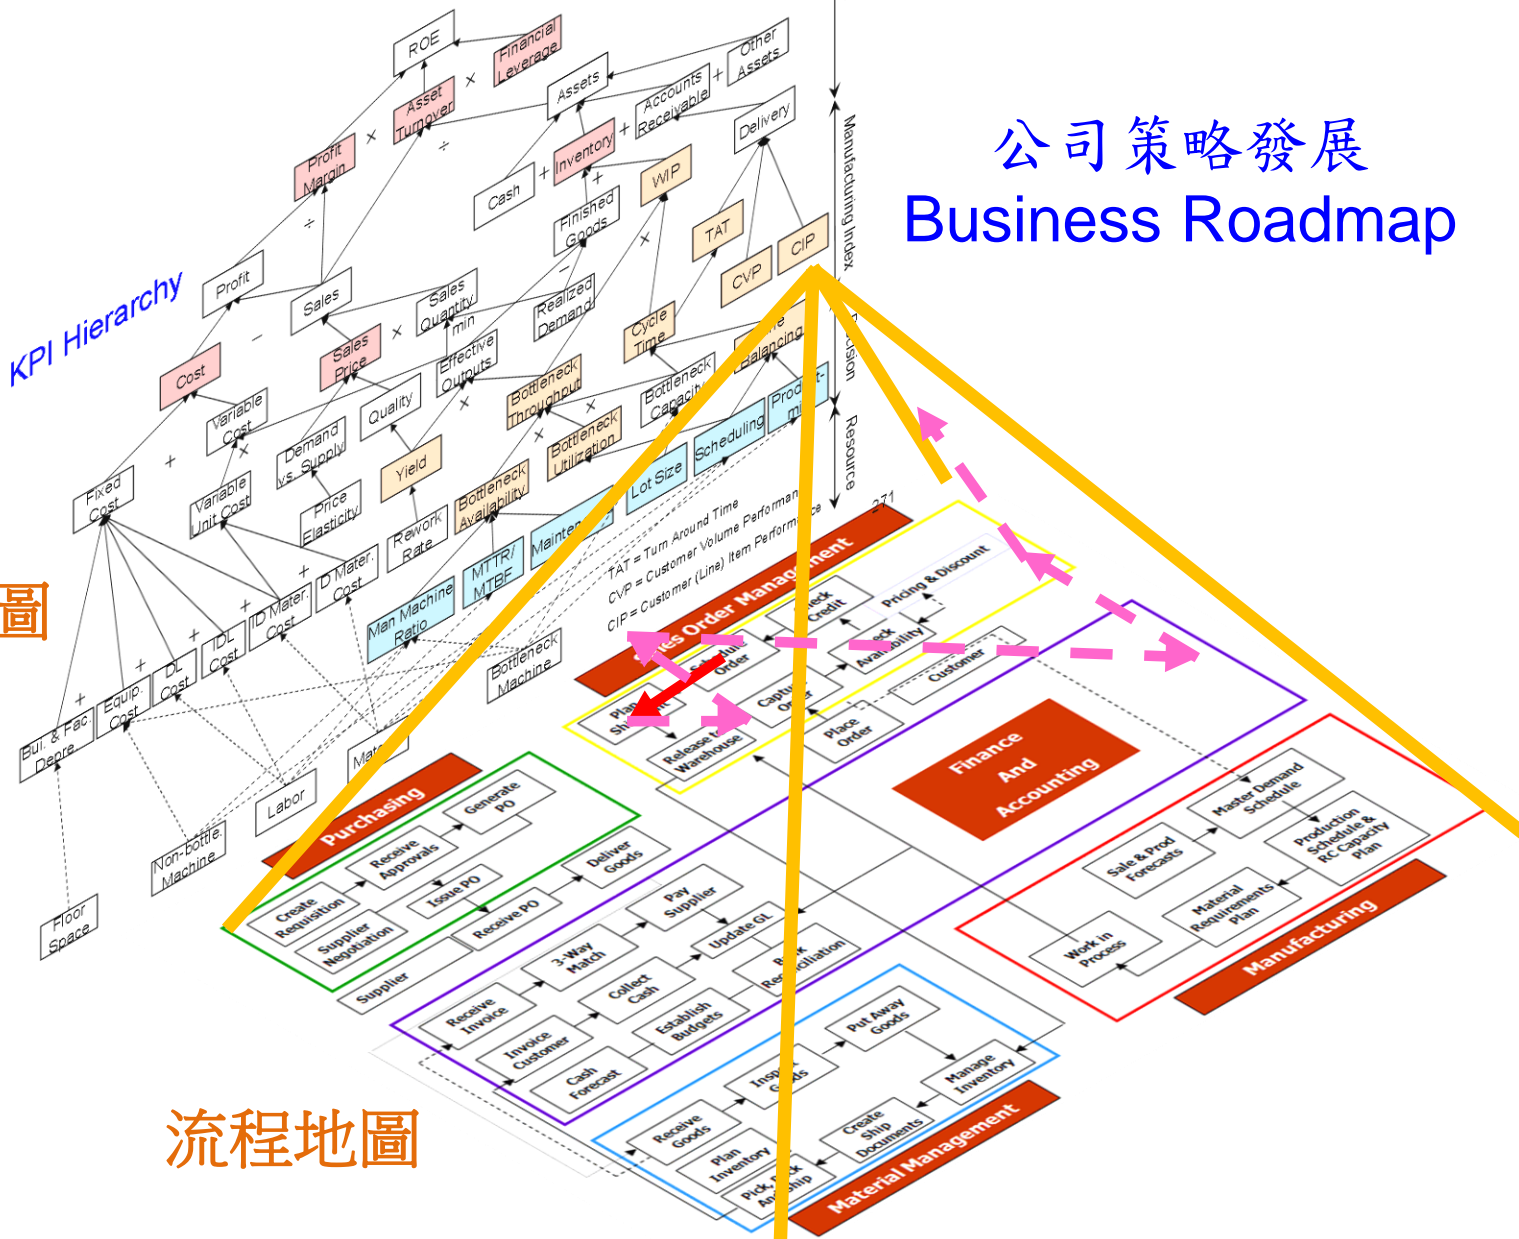
TAT = Turn Around Time  
CVP = Customer Volume Performance  
CIP = Customer (Line) Item Performance

公司策略發展  
Business Roadmap

財報地圖

KPI Hierarchy

流程地圖




# 問題定義

□ 怎麼找問題？擊破點？如何從點影響到面？(三要)

- 必要：處理部門內的事 → 點
- 需要：處理部門間的事 → 線
- 想要：處理部門與公司策略發展的連結 → 面

— 現在的專案執行，在地圖上所帶來的「連鎖效應」，最終如何達成公司策略目標

## 公司策略發展 Business Roadmap

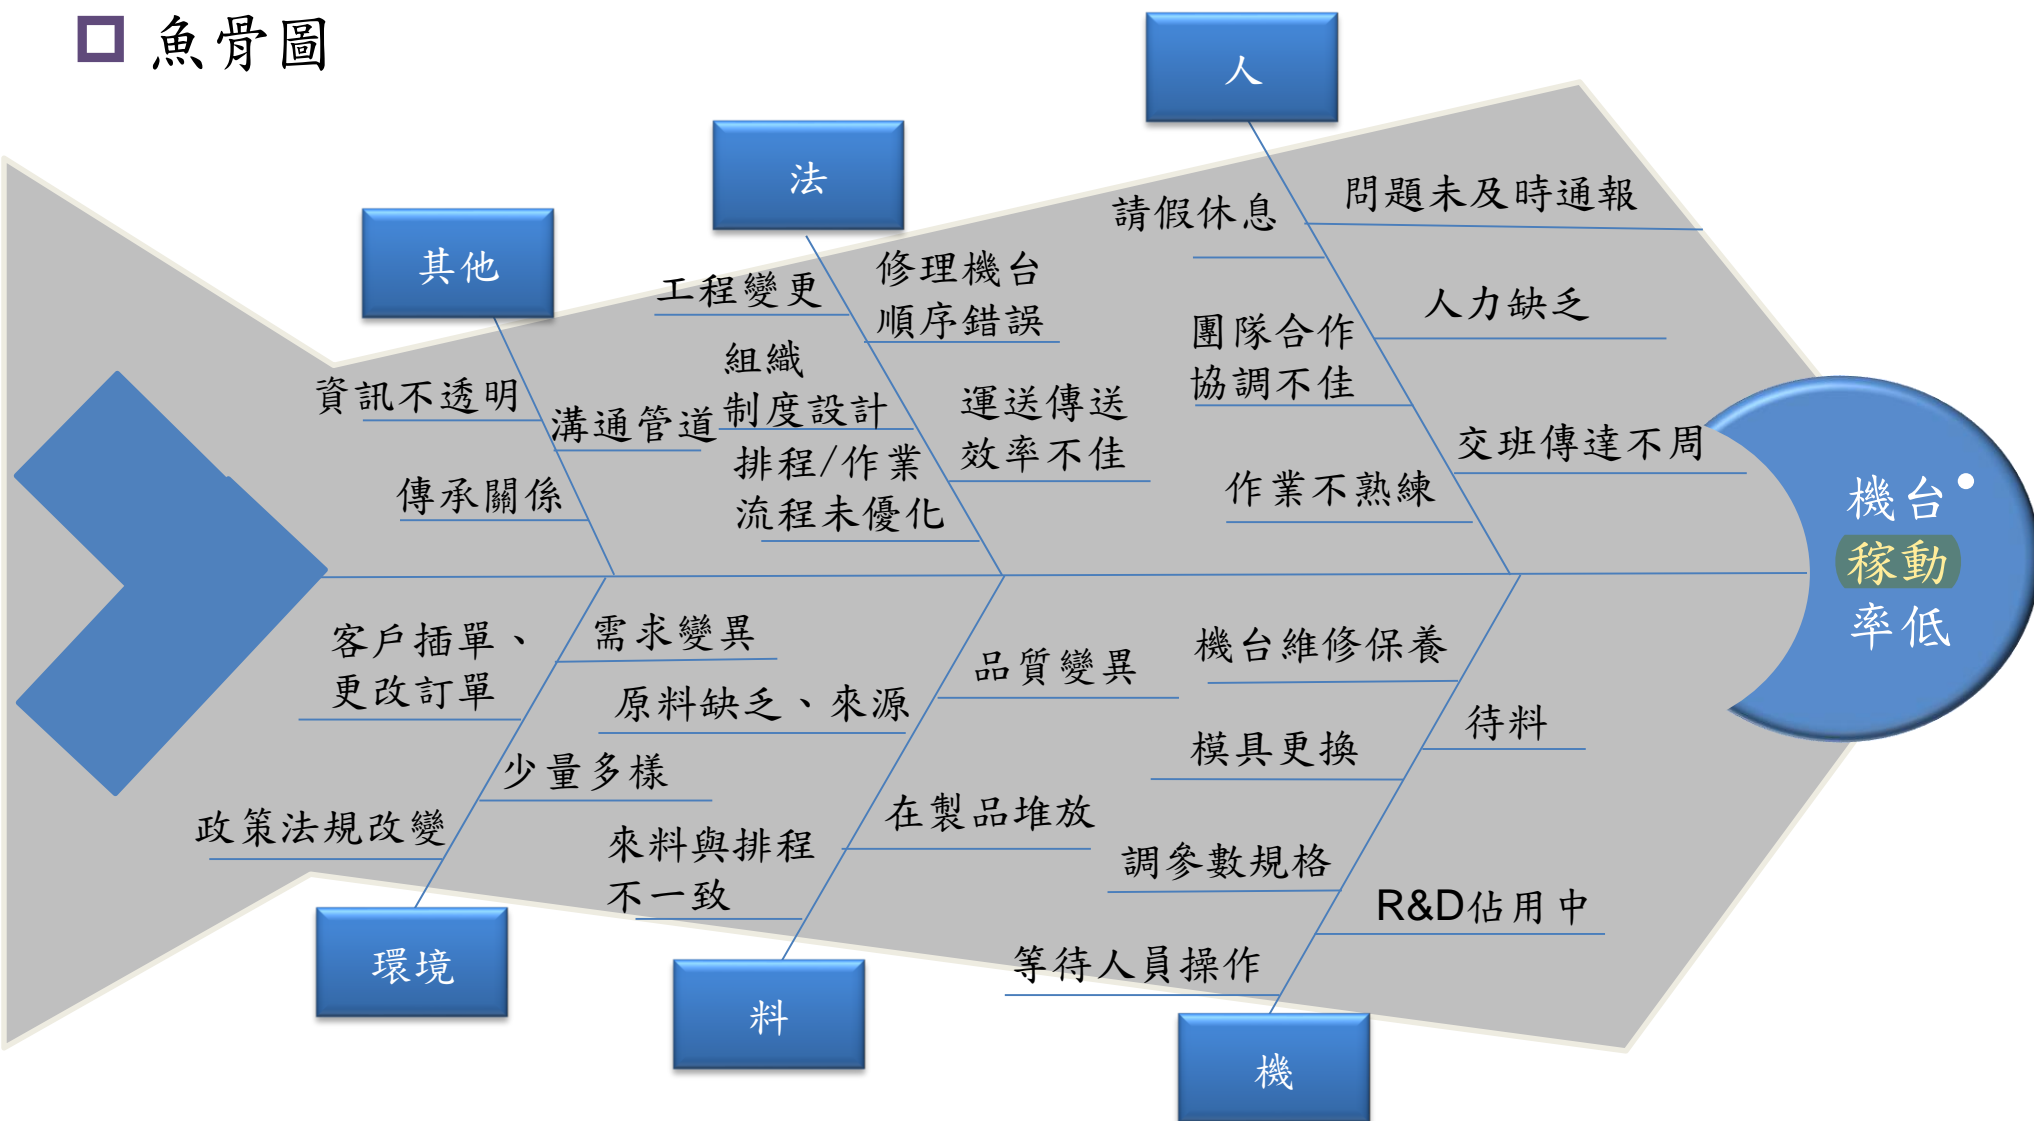


## □ 問題檢視

- 「根本原因識別」(root cause identification)，以「魚骨圖」的繪製進行由問題追溯原因的「因果關係」探索。
- 繪製「魚骨圖」須留意「彼此獨立且互無遺漏」(mutually-exclusive collectively-exhaustive, MECE)的準則。
- 若以探討某一個產品的缺陷為例，以「資源」視角（例如8M1I）所展開的魚骨圖，例如分別以「人、機、料、法、環」五大面向檢視導致缺陷可能的根因為何。
- 我們同樣也能建構一個以「系統流程」視角所展開的魚骨圖，可分別以系統的「流程策畫與建立、流程控制與責任歸屬、流程監視測量審核與評價、流程持續改善」四大步驟(PDCA)進行分析。
- 將「(管)資源」與「(理)流程」兩大視角整合在一起形成一個多階層的「魚骨圖」。
- 對「領域知識」的充分歸納，也有助於後續「數據收集」的細節掌握。

# 問題定義

## 魚骨圖



PDCA+魚骨圖

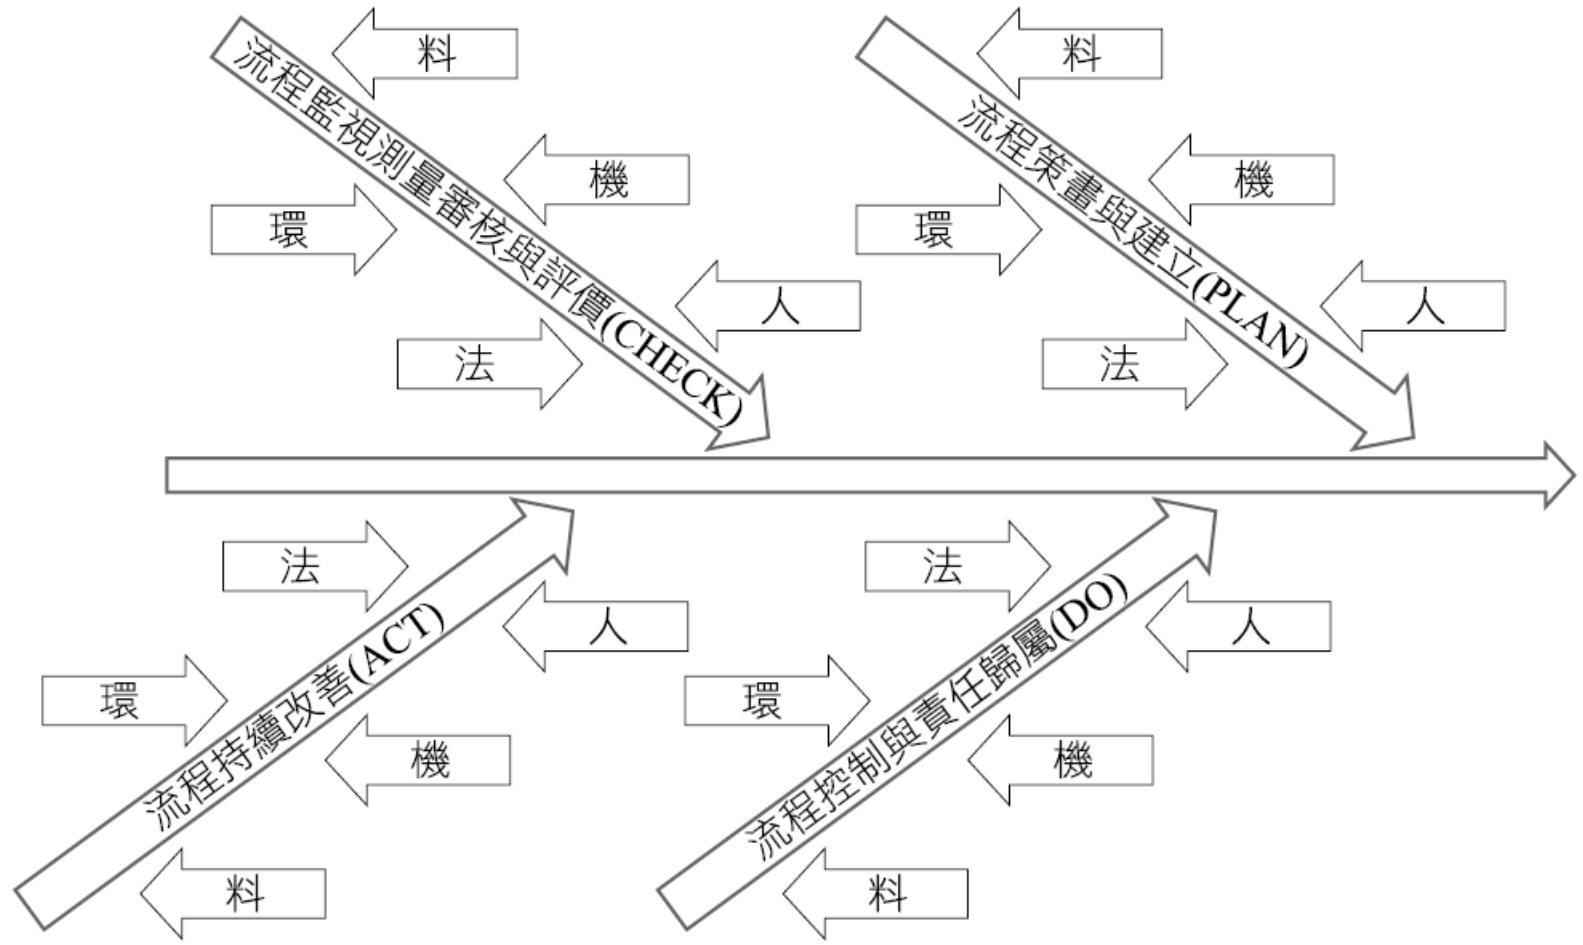


圖 4.4 流程與資源魚骨圖



# 問題定義

## 提案設計

- 考量整體與長期的「提案設計」。將組織關聯圖所找出跨部門業務的潛在問題及原因，以「跨部門業務檢核表」進行項目確認。
- 如AOI瑕疵檢測。列出「現有」(As-Is)以及提出方案來達到「期望」(To-Be)。
- 可有多個方案與業務檢核表。

## 提案評估

- 評估各提案可行性與獲利性




表 4.1 瑕疵檢測跨部門業務檢核表

跨部門業務檢核表（可文字或作圖回答）		
所屬__工程__處__技術開發__部門 / 課		
與他__品保__部門	As-Is：人工瑕疵檢測	To-Be：AOI 瑕疵檢測
流程業務（Who/What） 欲改善的業務與流程為何？資源與決策關係人為何？	流程（針對某一業務 / 功能）： 人工瑕疵檢測  資源（會牽涉到什麼資源）： 技術員、電子顯微鏡…	AOI 瑕疵檢測  儀器設備、大數據影像資料庫…
頻率與重要性（When） 該業務發生的頻率與重要性為何？	頻率（該業務發生頻率）： 高（一分鐘 XXXX 顆檢查）  重要性（該業務的重要性）： 高（關鍵 XXX 製程站品檢）	高（一分鐘可達 XXXX 顆檢查）  高（關鍵 XXX 製程站品檢）
問題（Why） 目前該業務有什麼問題、困難與挑戰？	問題（目前遇到什麼問題）： 人為誤判率高  問題的問題（根本原因在哪）： 誤判率高的理由是品檢員判斷不一、長時間眼睛疲勞…	AOI 可能偽陽性比率高（良品誤判為不良）  由於影像數據還在收集中，AI 模型訓練仍加強
功能與方法（How） 目前該業務處理的方法或提供什麼功能？	功能 / 方法（怎麼做這業務）： 人工操作電子顯微鏡用肉眼觀察量測  投入 / 輸出（功能投入 / 輸出）： 投入：技術員、電子顯微鏡 輸出：良品 / 不良品（bin code）	用 AI 光學影像自動判斷  投入：光學檢測機（拍照影像） 輸出：良品 / 不良品（bin code）
資料（Where） 業務中會用到的分析數據從哪裡收集？	資料（欄位名稱與資料來源）： 檢測員缺陷影像判斷結果、工程師複檢判斷結果  資料品質（資料可靠與否）： 判斷標籤品質差（尤其隨機缺陷的狀況人工不易分類）	缺陷影像、FDC 數據、製程參數  根據機台或光學影像解析度而異，數據跟抽樣頻率有關
績效 KPI 與 OKR 改善與衝突點（Conflict） 透過 To-Be 改善自己部門的 KPI，是否會造成該業務相關部門他們 KPI 的惡化	我方： 工程處：檢測員缺陷分類錯誤率高、需要複判且時間長 對口： 品保處：寧可重複檢測與重工，也不可放過瑕疵品送到客戶手上	工程處：AOI 可協助找出製程根因來源、縮短故障排除時間  品保處：AOI 使人力成本降低



## □ 數據分析

- 可分為「數據準備」(data preparation)與「模型建構」(modeling)。
- 前者專注於數據的「質與量」，後者於模型的「設計、訓練與解釋」。
- 數據準備是「數據專注」(data-focused)階段包含七個步驟：
  - 「數據收集」(data acquisition)
  - 「數據整合」(data integration)
  - 「數據清理」(data cleaning)
  - 「數據轉換」(data transformation)
  - 「特徵工程與數據增強」(feature engineering and data augmentation)
  - 「特徵挑選」(feature selection)
  - 「數據分割」(data partition)
- 模型建構是「模型專注」(model-focused)的階段，其包含三個步驟
  - 「模型建構」(model construction)
  - 「模型驗證與評估」(model validation and evaluation)
  - 「模型解釋」(model interpretation)
- 在「數據分析」的過程中，「數據視覺化」(data visualization)是在每一步驟都可使用到的重要技能。

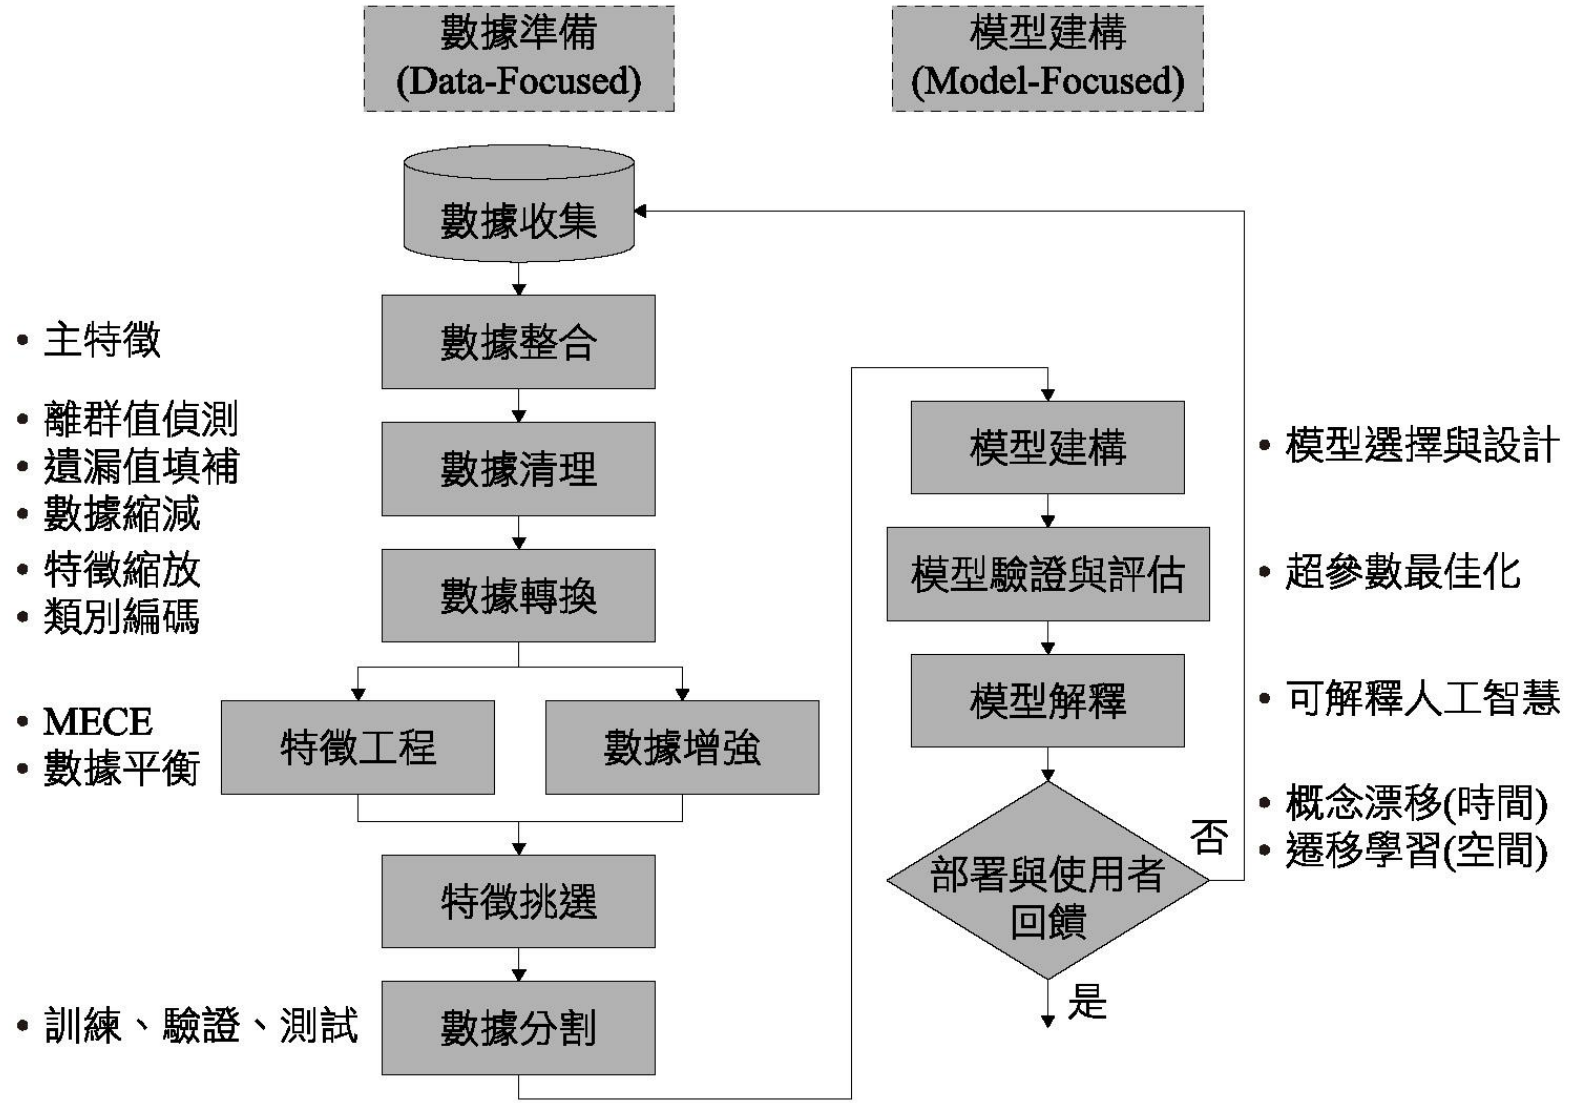


圖 4.6 數據分析階段

## □ 數據收集

- 可以是機台自身的紀錄(log)、資訊系統(例如製造執行系統)收集的設備參數與作業安排、單軸或多軸感測器(sensor)、問卷訪談、開放數據(public dataset)、網站爬蟲等。
- 數據收集需要決定例如感測器安裝位置、取樣頻率(例如振動訊號每秒取樣本點數)、品質抽檢頻率、品質檢測項目、光線強弱、紅光藍光、拍照角度等，這些設定會產生不同的數據品質與解析度。

## □ 數據整合

- 數據通常會從多個來源(例如資料庫、資訊系統、開放資料等)，包含了多個「數據集」(datasets)，因此我們需要依照這些數據集的「主要特徵」(key feature)進行表單串接與合併。
- 實際數據型態通常是混亂的，例如數據特徵的型態有「二元」(binary)、「連續型」(continuous)和「類別型」(categorical)，其中類別型特徵可能又存在相當多的「水準」(level)，因此整合上有一定的困難或常造成過多的遺漏值。

## □ 數據清理

- 在「數據整合」後，可對單一的大數據表單進行「數據清理」提升數據的品質，其中「數據清理」的課題主要包含了「數據縮減」(data reduction)、「離群值偵測」(outlier detection)與「遺漏值填補」(missing value imputation)。

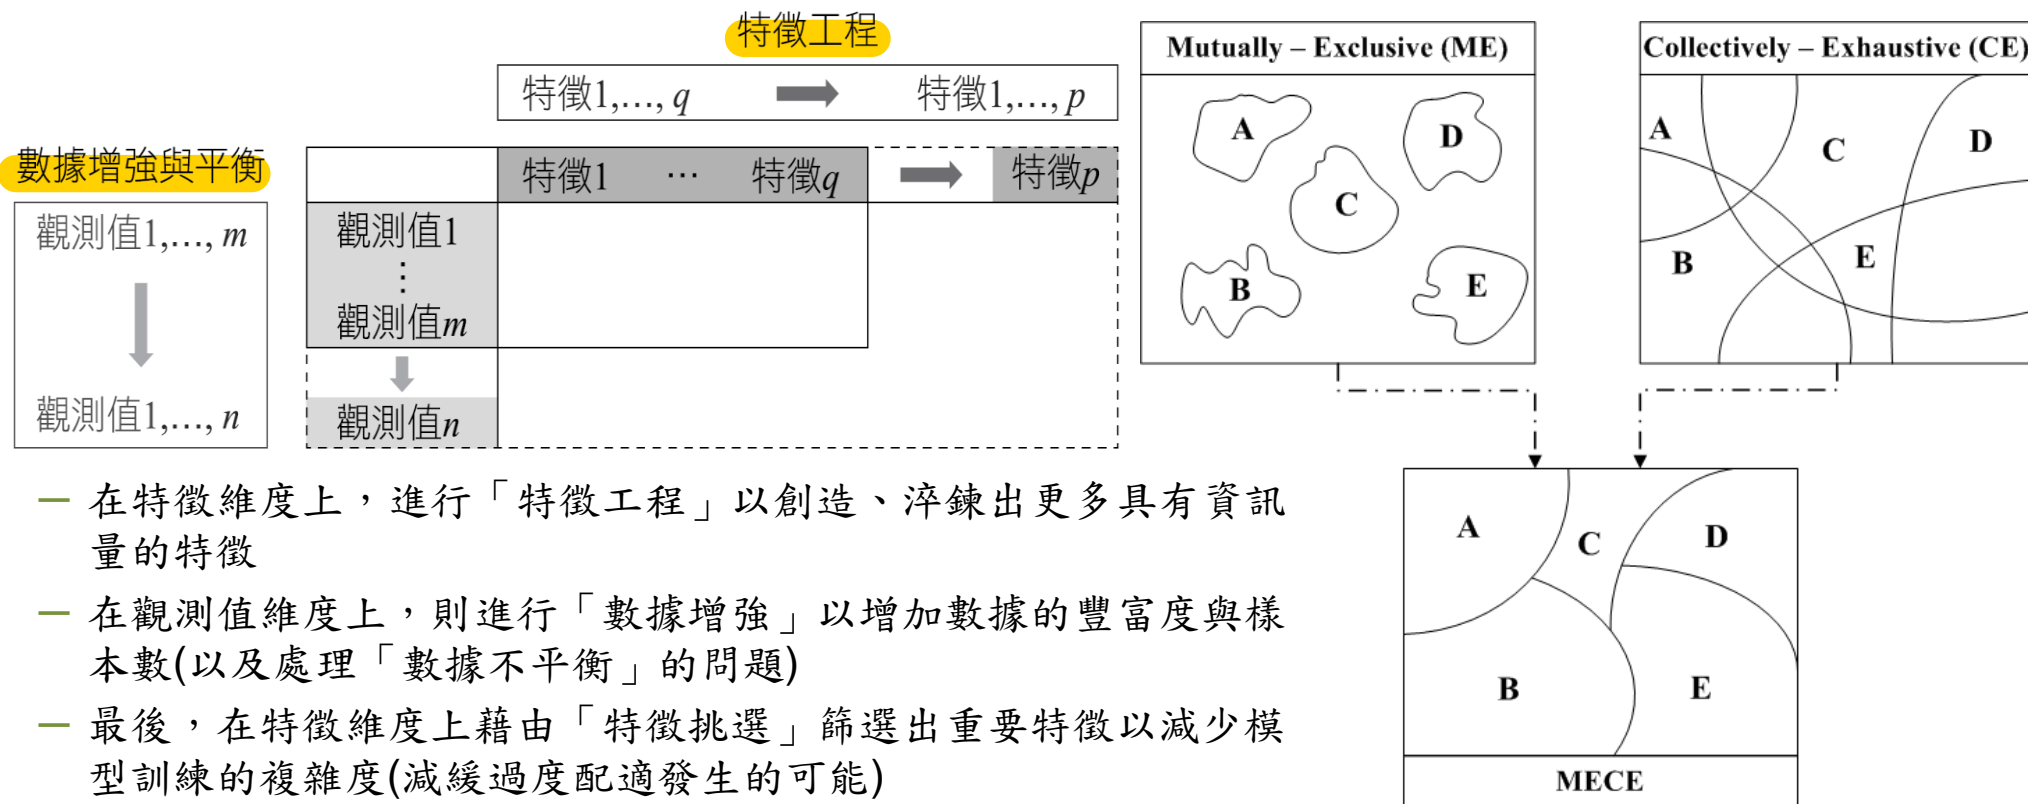
## □ 數據轉換

- 因為不同的預測模型所需要的數據型式以及特徵適合的範圍均有所不同，並且對數據的轉換也能消除單位的影響、或是改變特徵(x)或目標值(y)的分佈使得x與y兩者間的關係更易於建構。
- 其中「數據轉換」的方法可分為對「連續型」與「類別型」特徵的轉換，後者也被稱為「類別編碼」(category encoding)。

# 數據分析

## 特徵工程、數據增強與特徵挑選

- 經由前述的「數據整合」、「數據清理」、「數據轉換」後，提升數據部分的品質(處理噪音、離群值、遺漏值、單位等)與完整度，接著我們可以藉由領域知識再進一步強化數據的質與量。
- 資訊量「彼此獨立，互無遺漏」(MECE)，同時在特徵與觀測值維度上



## □ 數據分割

- 數據分割主要用於模型的驗證與評估，我們將數據分為訓練集、驗證集以及測試集，分別對應進行模型訓練、超參數最佳化以及模型評估。
- 實務上常使用「交叉驗證」(cross validation)將訓練集與驗證集交替地使用，除了優化超參數外，也避免訓練樣本或測試樣本的偏頗。

## □ 模型建構

- 有了「訓練集」後，便可以依照數據的特性、欲分析之目的以及各個方法論的優劣與適用性，選擇合適的模型進行預測模型的訓練，因此模型挑選經常權衡於預測準確度與解釋性(Hastie et al., 2009)。



# 數據分析：模型建構

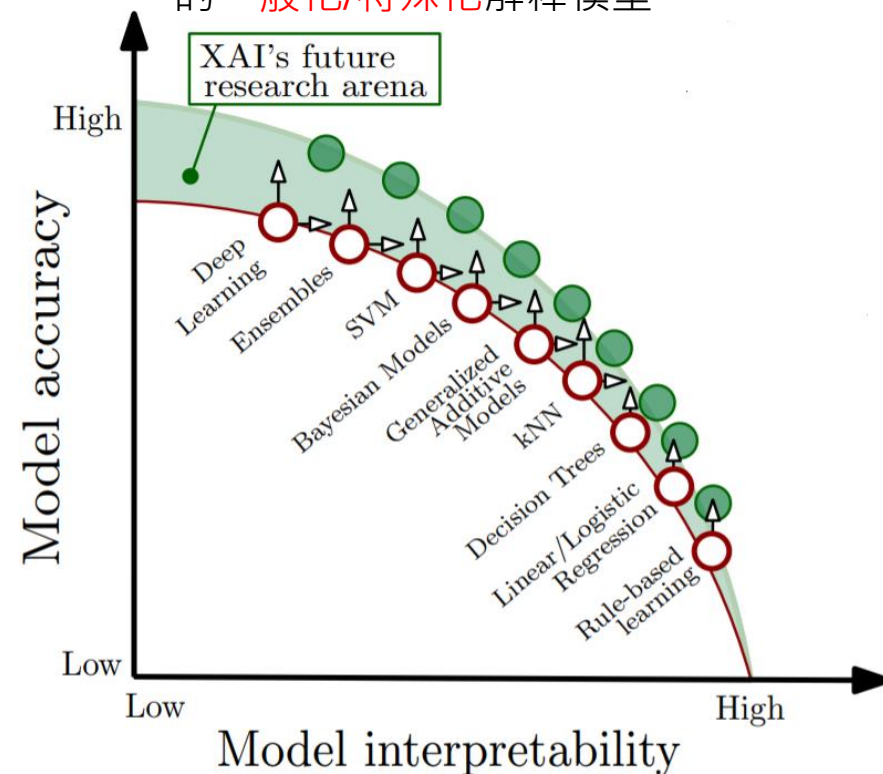
## Supervised Learning Models

- Regression, Logistic regression, Partial Least Squares (PLS), Multivariate Adaptive Regression Splines (MARS), SVM/SVR, **Decision Tree**, Random Forest, **LightGBM**, Deep learning (DNN, CNN, RNN, graphCNN), GAN...
- Time Series: ARIMA, SARIMAX, **LSTM**, convolutional LSTM, GRU, ...
- Accuracy Enhancement: Ensemble, Stacking, Attention, Transformer...

## Unsupervised Learning Models

- Clustering: Hierarchical(Ward's Method), non-hierarchical(k-means, k-medoids), density-based (DBSCAN), Spectral Clustering, SOM, ART, EM-GMM...
- Dimension Reduction: PCA, ICA, t-SNE...

數學建模用以產生適合各種不同情境的**一般化/特殊化**解釋模型



## Issues

Arrieta et al. (2019)

- Curse of Dimensionality, Overfitting vs. Underfitting, **Accuracy vs. Interpretation**, Data Imbalance

Arrieta et al., "Explainable artificial intelligence (XAI): concepts, taxonomies, opportunities and challenges toward responsible AI," <https://arxiv.org/pdf/1910.10045.pdf>.



TABLE 10.1. Some characteristics of different learning methods. Key: ▲ = good, ◆ = fair, and ▼ = poor. (revised from Hastie et al., 2009)

Characteristic	Neural Nets	SVM	Trees	MARS	k-NN, Kernels	ARIMA	GBM
Natural handling of data of “mixed” type	▼	▼	▲	▲	▼	▼	▲
Handling of missing values	▼	▼	▲	▲	▲	▼	▲
Robustness to outliers in input space	▼	▼	▲	▼	▲	▼	▲
Insensitive to monotone transformations of inputs	▼	▼	▲	▼	▼	▼	▲
Computational scalability (large $N$ )	▼	▼	▲	▲	▼	◆	▲
Ability to deal with irrelevant inputs	▼	▼	▲	▲	▼	▼	▲
Ability to extract linear combinations of features	▲	▲	▼	▼	◆	▼	◆
Interpretability	▼	▼	◆	▲	▼	▲	◆
Predictive power	▲	▲	▼	◆	▲	◆	▲

## □ 模型驗證與評估

- 對「訓練集」進行「模型建構」時，同時將「驗證集」作為「超參數最佳化」，並於「模型建構」後，以「測試集」來評估模型的整體表現。
- 例如可計算十折交叉驗證「均方差」(mean squared error, MSE)的平均值與標準差，相當於呈現模型的「準確性與穩健性」。
- 若我們同時建構多種模型時，最終可挑選表現最好的模型進行預測，或是用集成方法(ensemble)整合多個模型的預測能力。

### ● Evaluation Metrics

#### — Regression

- P-value, F statistic, AIC, BIC, WIC
- R-squared, MSE, RMSE, MAE, MAPE, sMAPE, RMSLE, cross entropy

#### — Classification

- Accuracy, Sensitivity(recall), Specificity, Precision, Miss rate (miss, type II error), fall-out (false alarm, type I error), F1-score, MAP, DICE
- DCG(discounted cumulative gain), NDCG, P@k (precision at k)

#### — Cross Validation

- Data split: training dataset (eg. 80%) and testing dataset (eg. 20%)
- K-fold CV, Random-Sampling CV (Holdout), stratified sampling CV, Leave-one-out CV, Time Series Nested CV, Group CV...

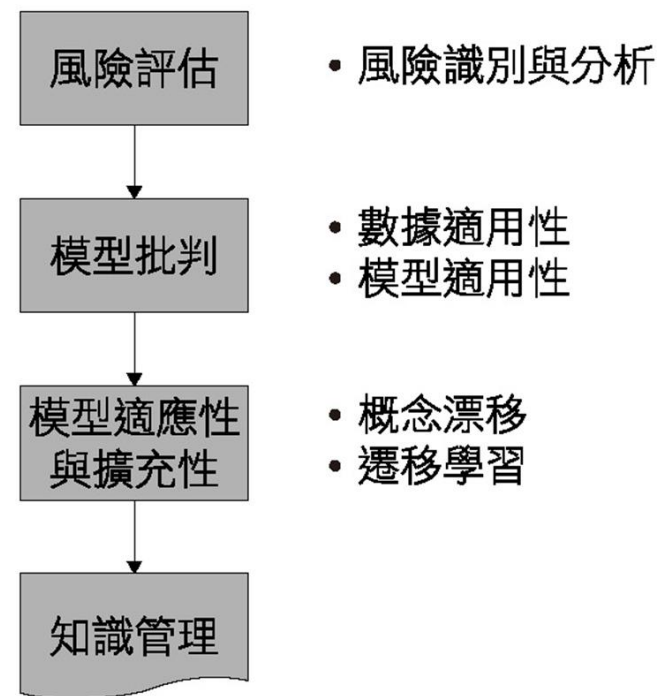
[https://en.wikipedia.org/wiki/Evaluation\\_measures\\_\(information\\_retrieval\)](https://en.wikipedia.org/wiki/Evaluation_measures_(information_retrieval))

## □ 模型解釋

- 現今已發展出眾多預測力高的模型(例如後續將介紹的「梯度提升機」、「深度學習」等模型)，然而模型的「預測力與解釋力」卻存在權衡的關係—「預測力」強大的模型往往犧牲的是「解釋力」。
- 在實務上，除了預測的精確度外，模型預測背後的推論依據也相當重要，若無法加以解釋與說明，對於模型的信任度將大幅降低。同時，當數據存在錯誤或偏見時，我們也難以發覺。
- 近年來「可解釋人工智慧」(eXplainable Artificial Intelligence, XAI)的出現，試圖提升模型的解釋力，使我們能理解每個樣本在複雜預測性模型裡的決策機制，這也使得我們能進一步結合領域知識判斷模型的可信度，從而得出數據科學的啟發。

## □ 決策支援

- 在數據科學中，「分析」與「預測」是過程，「決策」是目的。
- 在「決策支援」階段包含四個步驟
  - 「風險評估」(risk assessment)
  - 「模型批判」(model criticism)
  - 「模型適應性與擴充性」(model adaptation and scalability)
  - 「知識管理」(knowledge management)



## □ 風險評估

- 將權衡不同方案 / 預測模型執行後可能帶來的風險成本
  - 並非僅仰賴預測指標例如MSE
- 風險評估包含(行政院研究發展考核委員會，2009)
  - 「風險辨識」(risk identification)
  - 「風險分析與評量」(risk analysis and evaluation)
  - 「風險處理與驗證」(risk treatment and validation)

## □ 風險辨識(risk identification)

- 「風險辨識」是辨認風險發生的「5W2H」(what, who, when, where, why, how, how much)，將風險視為問題發生的可能以及量化其所衍伸的代價(對KPI的影響)。
- 風險的發生不僅限於部門內部，更可能存於部門間的三不管地帶，或是延伸到公司外的影響，因此對於風險辨識常以「系統觀」的角度，搭配「組織關聯圖」以及「資源 8M1I」進行定義與討論
- 風險發生與「問題定義」階段所牽涉到的部門、流程與資源相互呼應
  - 常見的風險像是「數據收集 / 品質風險」(數據質與量的好壞與成本)
  - 「模型預測風險」(預測錯誤的情形與成本)
  - 「上線風險」(上線時的挑戰或模型無法即時更新)等。

表 4.3 使用預測模型之風險辨識

AI 品質預測 / 生產週期預測模型			
所屬：製造部 KPIs: 每日生產量	(A)CIM/IT KPIs: 效率	(B)IE/PC KPIs: 成本、交 期、生產週期	(C)工程/R&D KPIs: 良率
1 人 (man)	(A1)配合執行人力	(B1)使用者的風險	
2 機 (machine)			(C2)跨部門協調/依賴性
3 料 (material)			
4 方法 (method)		(B4)流程分析	
5 測量 (measure)	(A5)數據取得		
6 時間 (minutes)	(A6)模型重新訓練		
7 資金 (money)			
8 環境 (mother nature/environment)			
9 資訊 (information)	(A9)一般化與特殊化		(C9)線上預測準確度
...			



## □ 風險分析與評量

- 找出風險事件發生機率、影響程度以及偵測機制之建立，並藉由風險比較，設定處理的優先順序。
- 風險事件可以理解為
  - 該事件所產生的負面「影響」(severity)(成本大小)
  - 問題發生的「機率」(probability)〔也就是預期狀況與實際狀況之間發生落差的可能性 (possibility)〕
  - 是否對於該風險目前有「偵測」(detection)機制
- 風險衡量為此三者的乘積
  - 風險 = 影響(S) x 機率(P) x 偵測(D)

表 4.4 風險機率、影響程度與偵測機制

等級	可能性分類	發生機率
3	幾乎確定	51-100%
2	可能	21-50%
1	幾乎不可能	0-20%

等級	衝擊後果	形象 / 財產損失	KPI 影響
3	非常嚴重	公司形象受損	嚴重惡化
2	嚴重	跨部門形象受損	中度惡化
1	輕微	部門 / 個人形象受損	輕度惡化

等級	偵測分類	偵測能力
3	無機制	低
2	有部分機制	中
1	有準確偵測機制	高

影響		風險分布		
非常嚴重(3)		(B1)	(B4)	
	嚴重(2)	(A5)	(A9) (C9)	(C2)
	輕微(1)		(A6)	(A1)
		幾乎不可能(1)	可能(2)	幾乎確定(3)
		機率		

影響		風險分布		
非常嚴重(3)		高度危險 3 管理階層需督 導所屬研擬計 畫並提供資源	高度危險 6 管理階層需督 導所屬研擬計 畫並提供資源	極度危險 9 須立即 採取行動
	嚴重(2)	中度危險 2 必須明定 管理階層的 責任範圍	高度危險 4 管理階層需督 導所屬研擬計 畫並提供資源	高度危險 6 管理階層需督 導所屬研擬計 畫並提供資源
	輕微(1)	低度危險 1 以一般 步驟處理	中度危險 2 必須明定 管理階層的 責任範圍	高度危險 4 管理階層需督 導所屬研擬計 畫並提供資源
		幾乎不可能(1)	可能(2)	幾乎確定(3)
		機率		

圖 4.9 風險評量九宮格

表 4.5 風險分析與評量

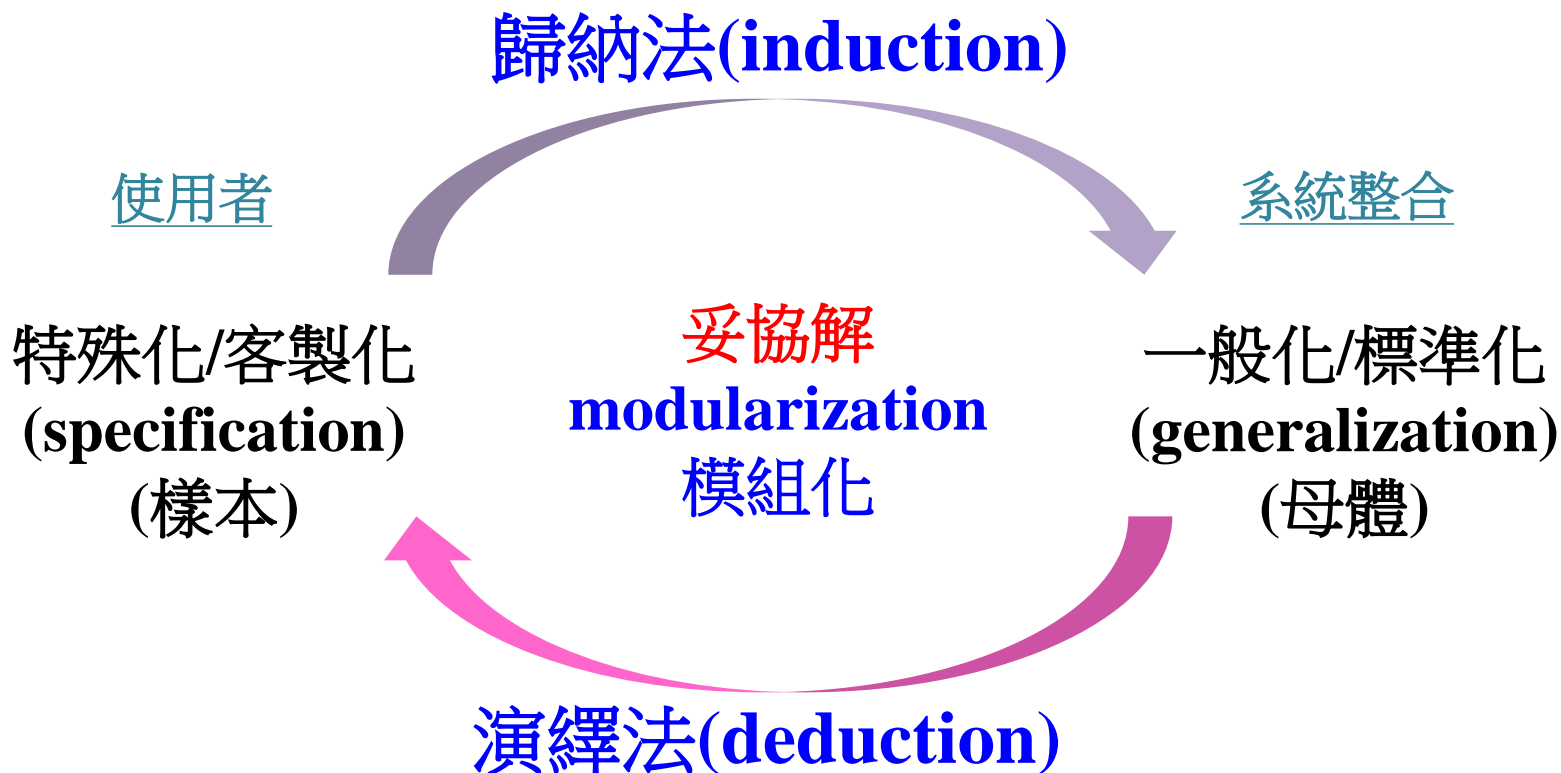
風險	風險本質分析			風險等級	風險處理	殘餘風險等級
項目	影響 (S)	機率 (P)	偵測 (D)	(S) x (P) x (D)	可能控制機制 或作法	(S) x (P) x (D)
B1	2	3	3	18	作法 1	2x2x2=8
C9	2	2	3	12	作法 2	1x2x2=4
...						

# 決策支援：模型批判

## □ 模型批判

### ● 主要用於回過頭審視

- 「**數據**適用性」(data applicability)與「**模型**適用性」(model applicability)
- 模型建構與預測是在「一般化與特殊化」之間及「全域與區域」之間進行切換
- 模型建構是將多個樣本形成一種歸納過程，而模型預測是對個體數據預測形成一種演繹過程，因此「批判」可由擊破歸納法與演繹法的原則去思考



## □ 模型適應性與擴充性

- 「數據分析」多為探討單一時間區間與空間範圍的數據與模型
- 實際上數據會因時空不同而具有不同的特性
  - 特徵或目標值的分配或關係可能會變化
- 期望能建構一個「分析架構」適應數據在時間上的變化 以及在空間上的推廣，讓「預測力」在不同的情境下都能保持一定水準(取得時間與空間上「一般化與特殊化」的權衡)，使得模型具備「適應性」與「擴充性」

## □ 概念漂移(0→1)

- 建構模型時數據使用的時間區間？
- 什麼時候模型預測不準了需要重新訓練模型？
  - → drift detection
- 模型不準的根本原因為何？
  - → drift understanding
- 又或是如何即時更新模型？
  - → drift adaptation




圖 15.2 漂移的類型與特性

## ● 遷移學習(Transfer Learning)(1→N)

—描述的則是基於數據分布在空間上所存在的部分差異與相似（可能部分的特徵空間有交集）而使用的學習方法

➤ 例如希望將某一製程/機台的模型遷移到另一類似或相關製程/機台

—「既有的」數據 → 「來源數據」（source data）

—「欲學習的」數據 → 「目標數據」（target data）

## ● 「遷移學習」期望能利用「來源數據」的潛在知識轉移至「目標數據」的學習

—數據依據其「特徵分佈」與「特徵與目標值關係」分為「領域」（domain）與「任務」（task）

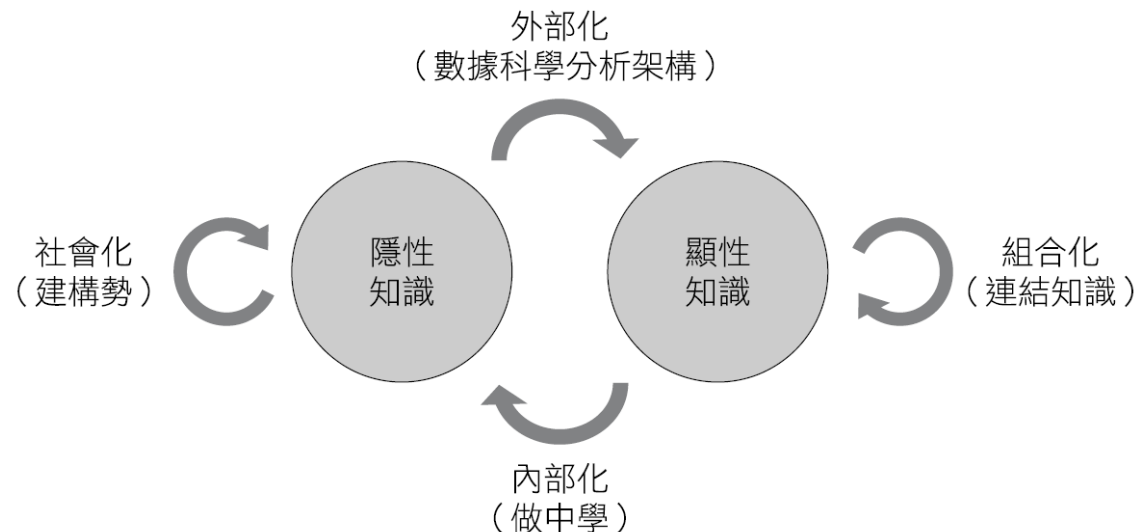


## □ 知識管理

- 對新 / 舊知識和經驗進行「創建」、「創新」、「執行」與「傳播」的一種系統管理，其中這些知識和經驗涵蓋小至個人的知識經驗，大至組織的商業流程
- 在理論及應用層面上更包括了「資訊科技應用」、「學習型組織」、「人事管理」以及「企業文化」等
- 常用的「知識管理」方法包括了「師徒制度」、「實務經驗 / 讀書分享會」(共享內部外部知識的方式)、「跨項目 / 部門學習」(能獲得更廣的系統觀的思維)、「顧問 / 專家 / 案例庫」(讓知識尋求者可找到專家)。

- SECI模型

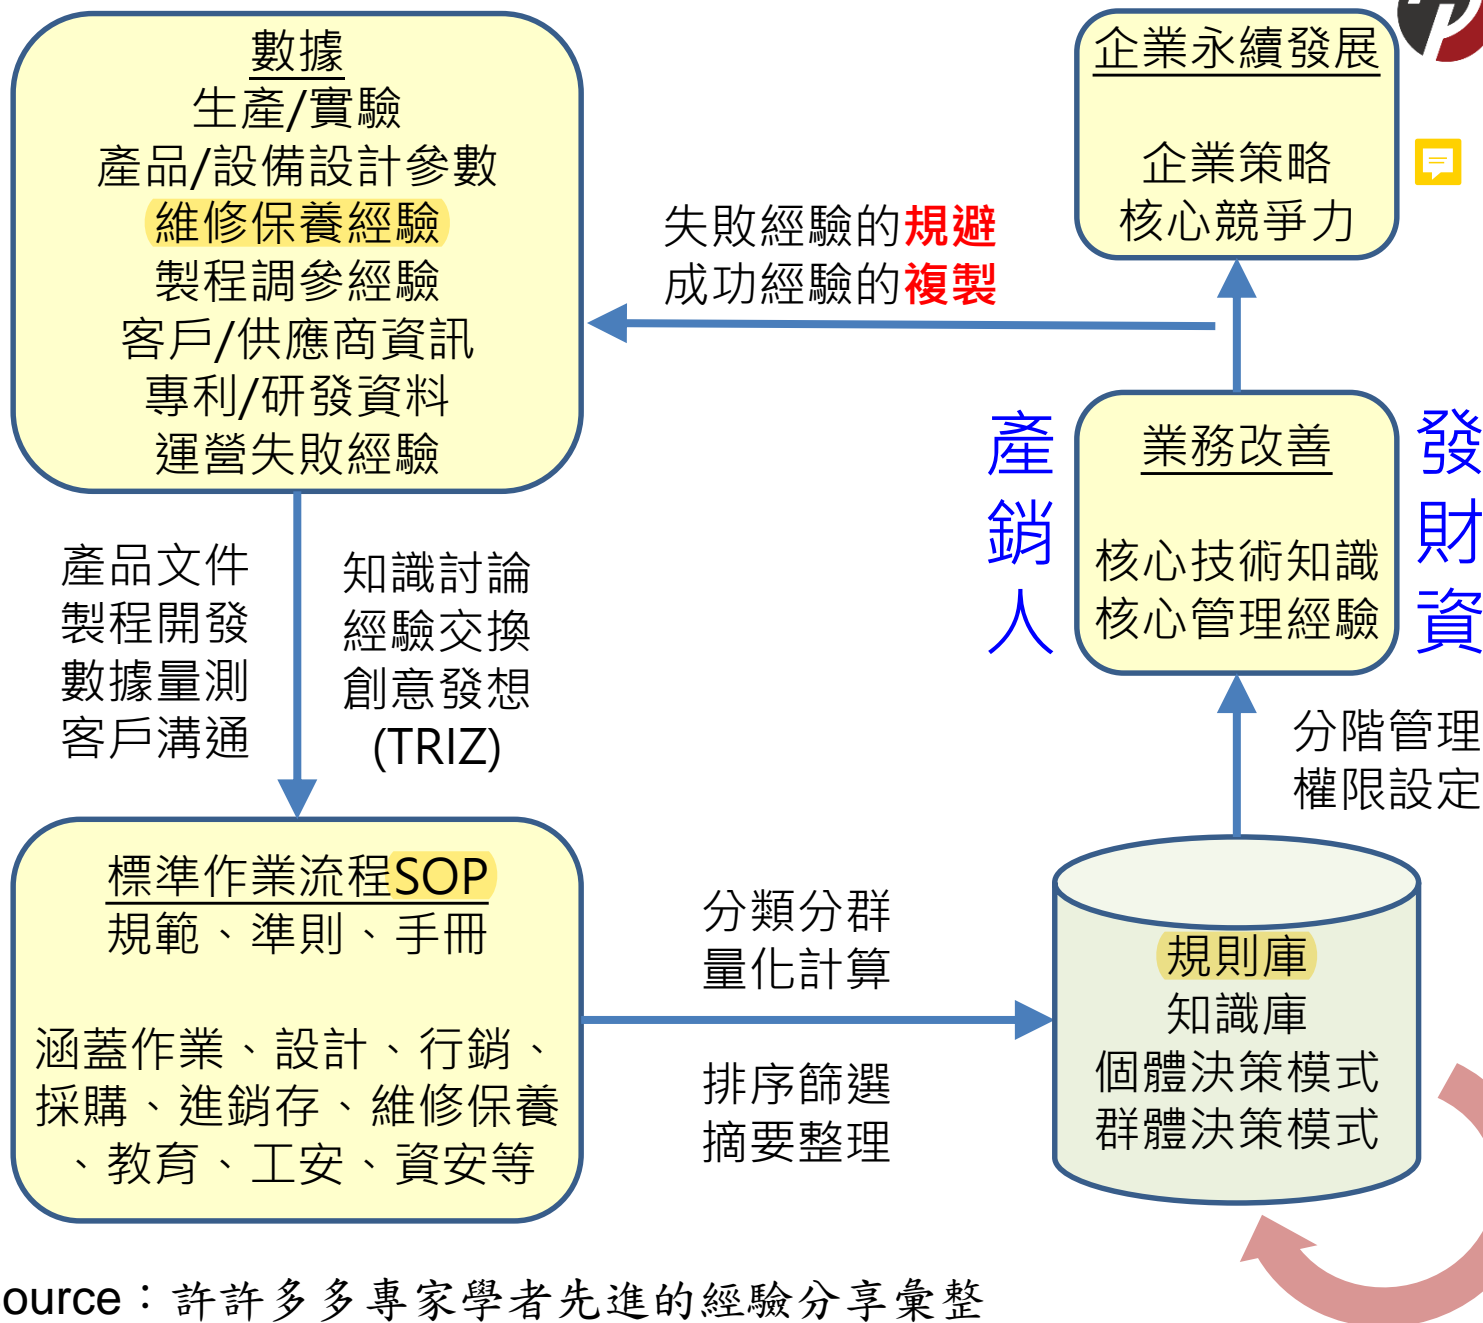
- Socialization
- Externalization
- Combination
- Internalization



資料來源：Nonaka and Takeuchi (1995).

重點業務範疇(資源、流程)

省檢  
思討



Source：許許多多專家學者先進的經驗分享彙整

# 數據科學分析架構

問題定義

1. 有價值/品質的
2. 異質多元的
3. 場域知識相關

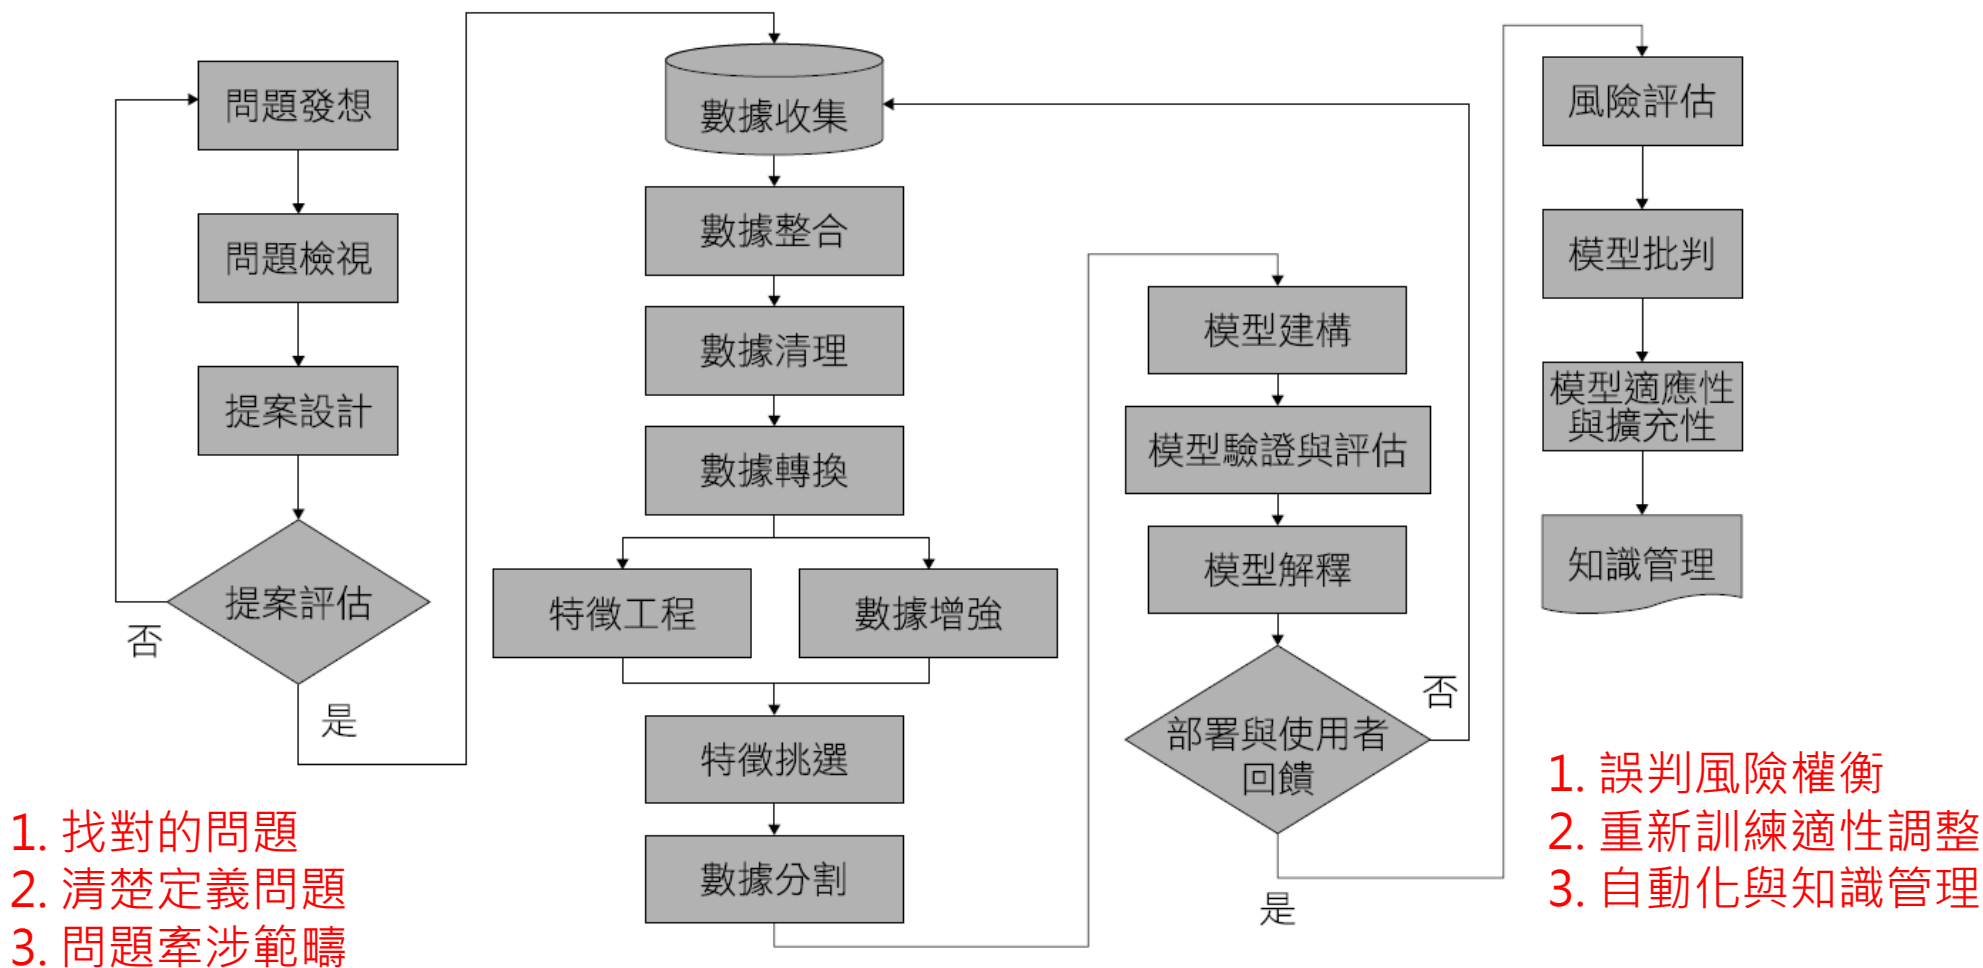
數據分析

1. 假設與背景
2. 使用時機
3. 優與劣

決策支援

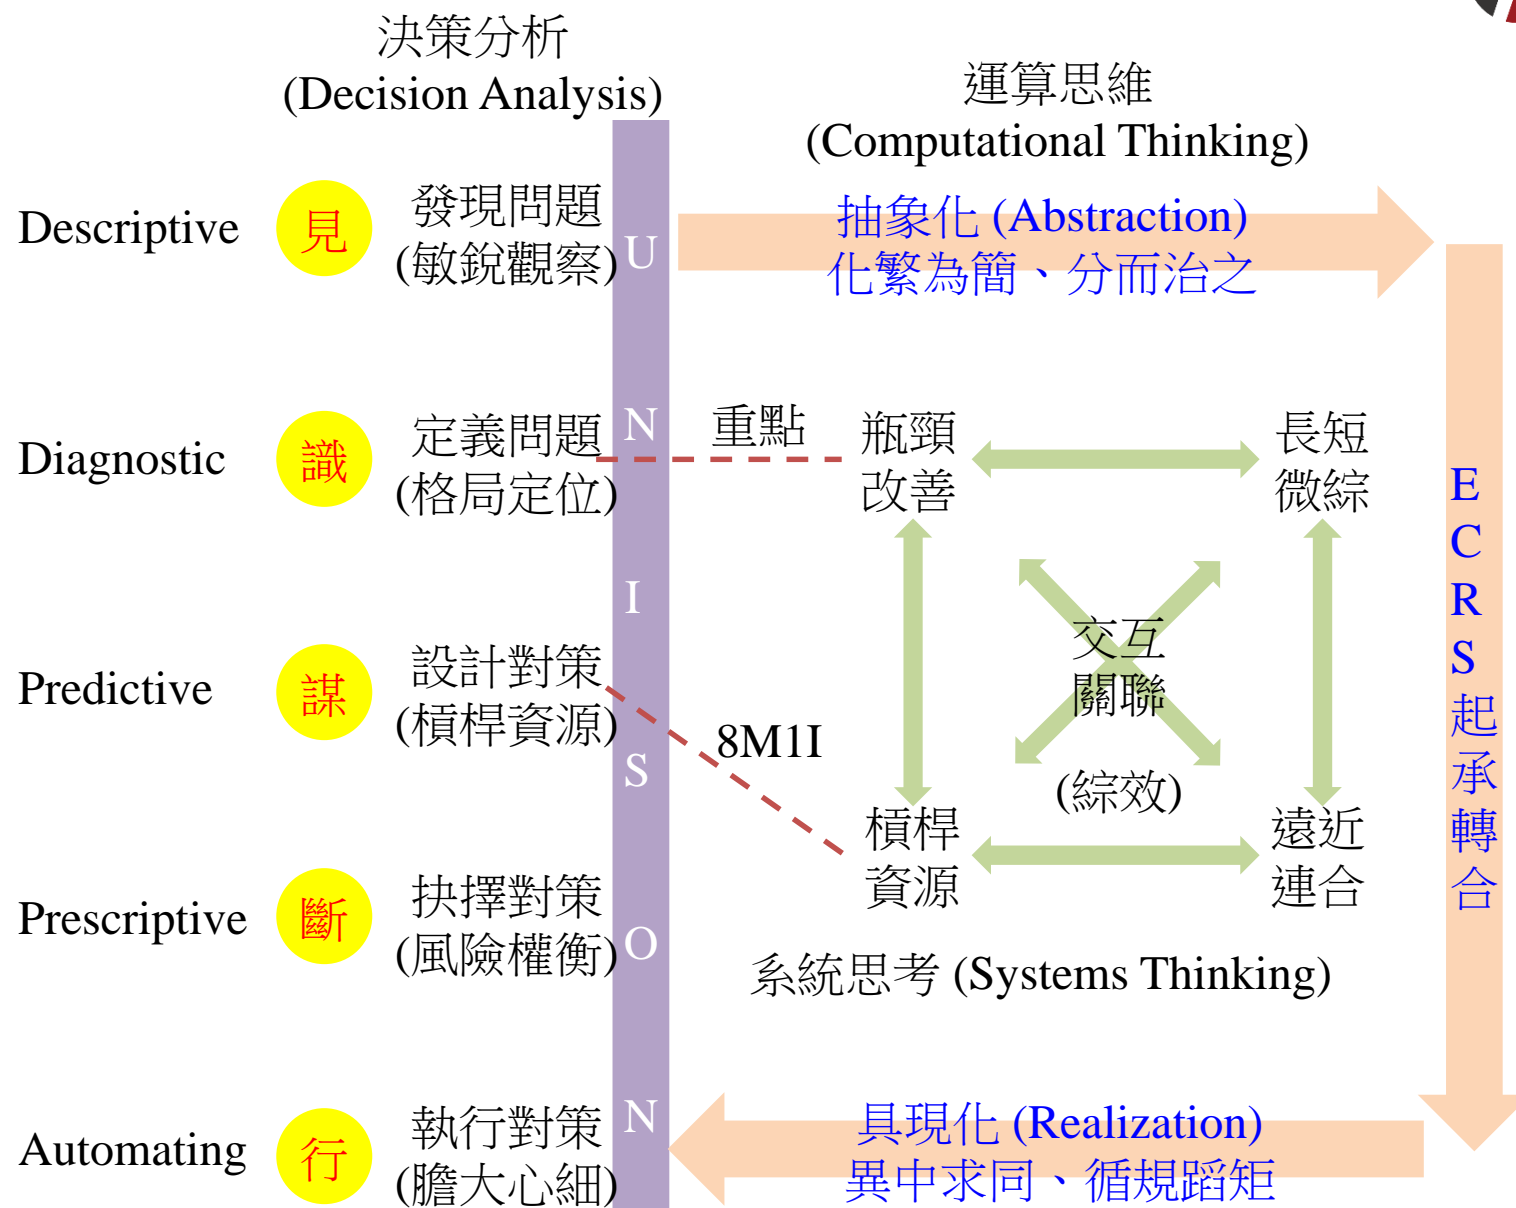
數據準備  
(Data-Focused)

模型建構  
(Model-Focused)

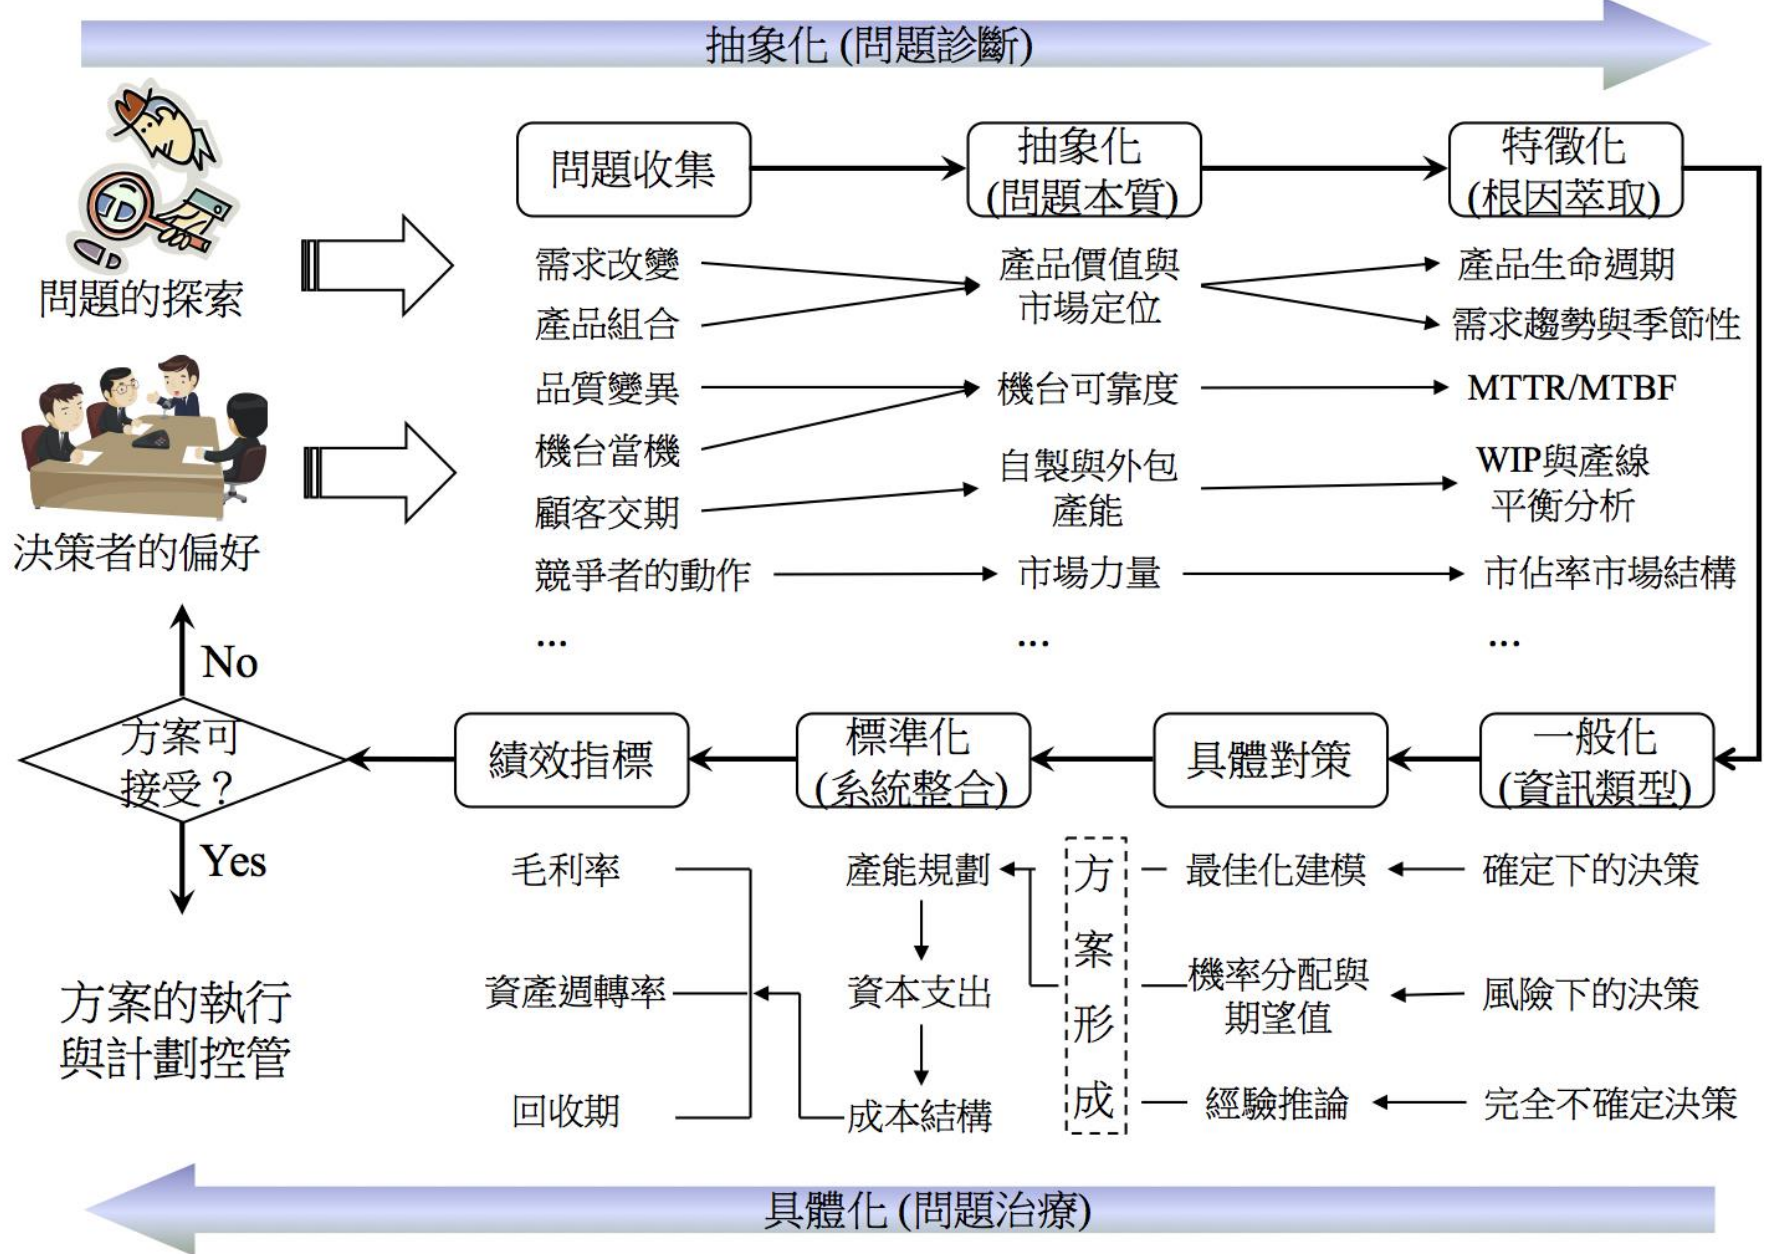


# 問題解決過程(Problem Solving)





生產力(productivity)、品質(quality)、成本(cost)、交貨期(delivery)、安全(safety/security)、員工士氣(morale)、綠色永續(green)





- 數據科學分析架構（DSAF）與系統運算決策（SYCON），將決策思維與分析架構整合一起陳述，以期望達到「見微知著、見樹又見林」的效果，從點、線、連結到面的整體系統觀。
- 在SYCON所包含的運算思維、系統思考與決策分析，主要是「內化」以提升邏輯思維能力；在DSAF涵蓋了問題定義、數據分析與決策支援，主要是「外顯」以實作增強系統開發技術能力。前者為「決策力」、後者為「執行力」。
- SYCON一開始專注於問題定義（也就是瓶頸），從大系統觀找到一個利基點且影響力大的問題點切入。如同《老子》所述：「圖難於其易，圖大於其細」，解決難題要從易處著手，想做大事要從細微之處著手。
- 然在SYCON的最後階段也呈現「決策後省思」，也就是「回饋機制」（feedback）。決策結果發現錯誤便需要立即修正決策，切勿一錯再錯、釀成大禍，以此機制重新校準且提升決策品質。
- 事實上，「數位神經系統」（digital nervous system, DNS）是指一個企業迅速收集有效的訊息，將其系統化地組織為資訊流，並以最快的速度將其傳遞給適當的部門或人員，以供協助相關部門做出最佳的決策（Gates, 1999）。



## □ 學習型組織 (Peter Senge, 《第五項修練》, 1990)

- 由於環境變遷之快速，系統需要能夠及時反應外在環境的變化，不論是要「逃避環境」、「適應環境」、還是「改變環境」，這個系統都需要「做(do something)」些什麼以在環境中求生存

## □ 書中提出一個重要問題：企業和組織，如何發展適應環境的能力呢？

- 綜觀全書後的簡要答案：組織不能再依靠單一領導人來運籌帷幄，而必須要全體上下合作，不斷學習與創新。→ 「學習型組織」


## □ 我以為「智慧要分享、利益要分配、責任要分擔、行動要合一」

$$\text{組織績效} = (\text{決策力} \times \text{執行力}) \text{分享力}$$

- 學習型組織不單是“喊”出來的...更是一步步踏實地“走(執行)”出來的...

## □ 因此學習型組織與其說是一個主動成長的組織，還不如說是一個面對環境改變「不得已」進而調整自己，提升自己免疫力(immune)的一個系統.....

# Thanks for your attention



NTU Dept. of Information Management  
name: 李家岩 (FB: Chia-Yen Lee)  
phone: 886-2-33661206  
email: [chiayenlee@ntu.edu.tw](mailto:chiayenlee@ntu.edu.tw)  
web: <https://polab.im.ntu.edu.tw/>